모델을 복잡하게 만들면 더 똑똑해질까?

다항회귀로 확인하는 과소적합 · 과적합 · 일반화

훈련 데이터를 가장 잘 맞히는 모델이 정말 가장 좋은 모델일까?

오늘의 실험

새로운 알고리즘보다 'AI 모델을 평가하는 사고방식'을 확인한다.

- 모델을 복잡하게 만들면 훈련 성능은 어떻게 변하는가?
- 훈련 성능이 좋아지면 테스트 성능도 항상 좋아지는가?
- 보지 않은 데이터에서도 잘 작동하는 모델은 어떻게 찾는가?

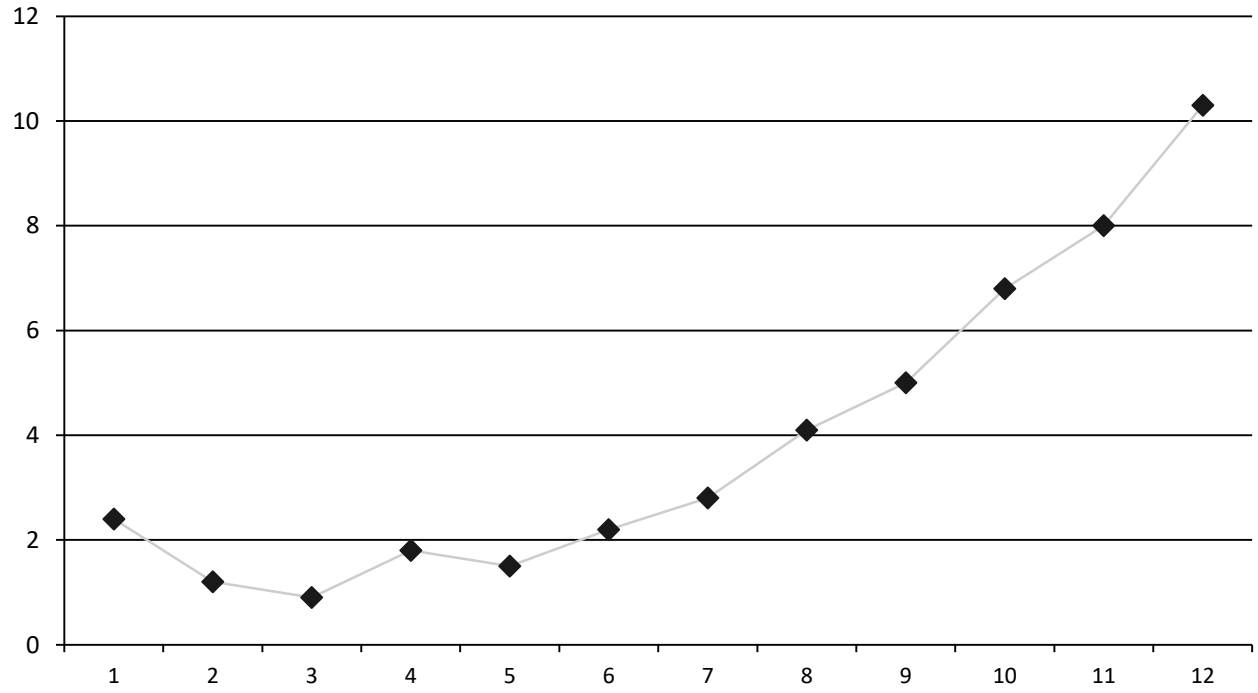
학습 → 예측 → 평가 → 일반화

핵심 조작
Polynomial degree

핵심 비교
Train MSE vs Test MSE

데이터에는 규칙과 잡음이 함께 존재한다

모델의 목적은 관측된 모든 점을 그대로 외우는 것이 아니다.



관측값 = 규칙 + 잡음

- 전체적으로는 일정한 패턴이 존재
- 각 관측값에는 우연한 변동이 포함
- 잡음까지 학습하면 새로운 데이터에 약해질 수 있음

모델의 복잡도를 조절해 보자

다항회귀의 degree를 하나의 '복잡도 다이얼'로 사용한다.

Degree = 1

단순한 모델

과소적합 가능

Degree = 3

적절한 곡선

패턴을 잘 포착

Degree = 15

매우 복잡한 모델

과적합 가능

이번 실험의 하이퍼파라미터: degree

공정하게 실력을 측정하려면

학습에 사용한 데이터와 평가에 사용할 데이터를 분리한다.



- Train: 모델의 매개변수를 학습
- Test: 학습이 끝난 모델의 일반화 성능 확인
- 이번 25분 실습에서는 원리를 명확히 보기 위해 Train/Test만 사용

첫 번째 실험: degree만 바꾸어 본다

코드 문법보다 결과의 변화에 집중한다.

```
degree = 1

# 실행 후
degree = 3

degree = 15
```

- 모델의 곡선은 어떻게 변하는가?
- 훈련 데이터를 얼마나 가까이 따라가는가?
- 지나치게 구불구불해지는 순간은 언제인가?

학생이 직접 바꾸는 것은 숫자 하나

눈으로만 판단하지 않는다

MSE로 훈련 데이터와 테스트 데이터의 오차를 각각 측정한다.

$$\text{MSE} = \text{평균}\ (\text{실제값} - \text{예측값})^2$$

Train MSE
학습한 데이터에서의 오차

Test MSE
보지 않은 데이터에서의 오차

좋은 모델이라면 어느 MSE가 작아야 할까?

진짜 실력은 Train과 Test의 차이에서 나타난다

훈련 오차가 작다는 사실만으로 좋은 모델이라고 할 수 없다.

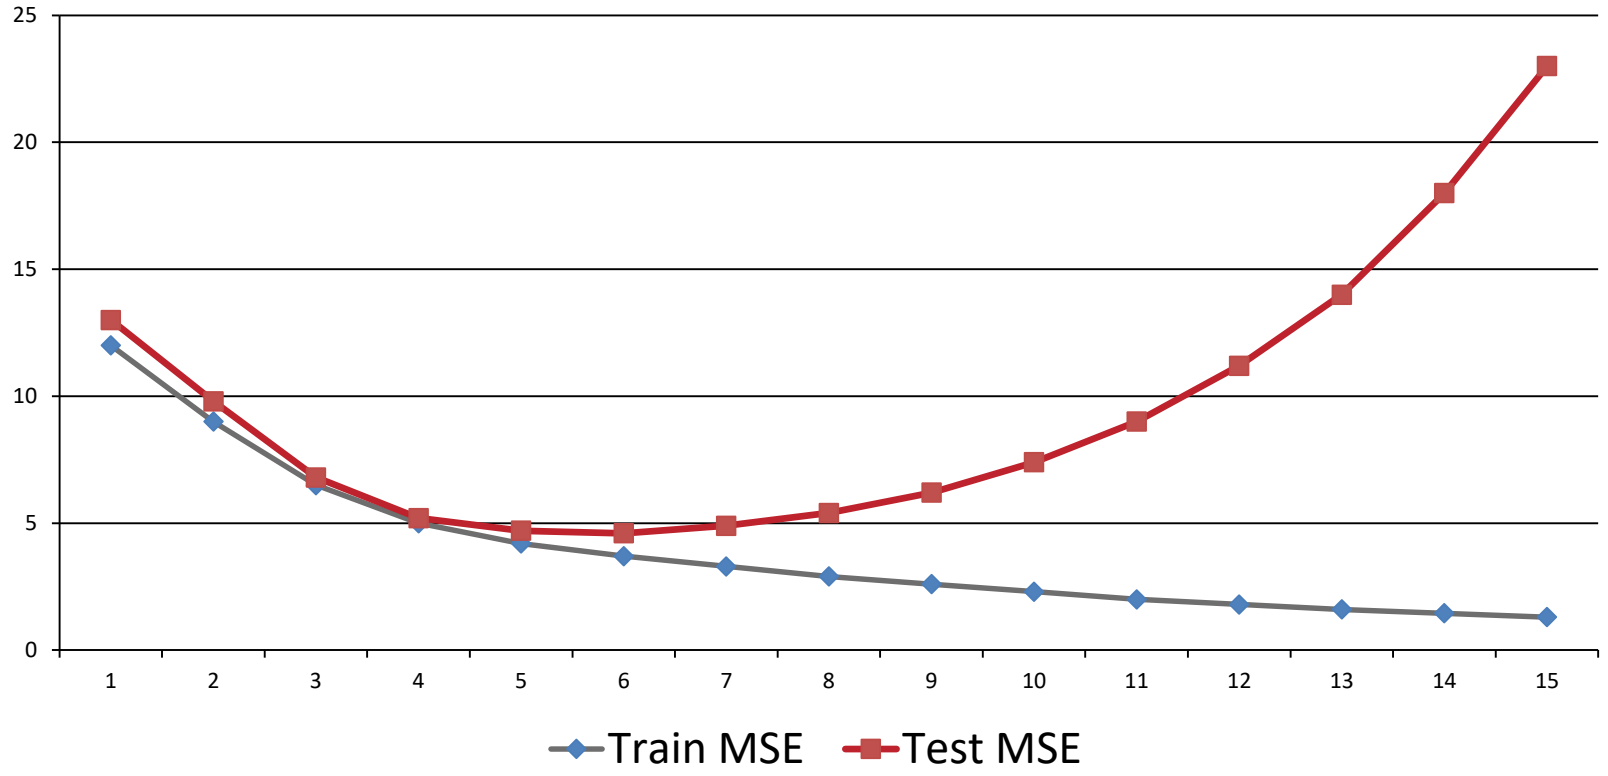
상태	Train MSE	Test MSE
과소적합	큼	큼
적절한 학습	작음	작음
과적합	매우 작음	**다시 커짐**

과적합 = 학습을 못한 모델이 아니라 훈련 데이터를 '너무 잘' 학습한 모델

Train MSE ↓ ≠ Test MSE ↓

모델 복잡도와 일반화

복잡도가 증가하면 Train MSE와 Test MSE는 다르게 움직일 수 있다.



Underfitting

Good generalization

Overfitting

생성형 AI를 실험 조교로 활용하기

코드 생성보다 '결과 해석'과 '다음 실험 설계'에 활용한다.

결과 해석

"degree=15에서 Train MSE는 매우 작지만 Test MSE는 커졌다. 이 결과를 과적합과 일반화라는 용어를 사용하여 설명해 줘."

다음 실험 설계

3주차 실습 과제



"이 모델이 과적합되었다는 것을 더 확실하게 확인하려면 어떤 실험을 추가하면 좋을까? 코드를 작성하지 말고 실험 방법부터 제안해 줘."

AI에게 답을 대신 만들게 하기보다, 내가 얻은 결과를 설명하게 한다.

오늘의 결론

좋은 AI 모델의 기준은 '훈련 데이터 암기'가 아니라 일반화이다.

01 복잡한 모델이 항상 좋은 모델은 아니다.

02 훈련 성능이 가장 높은 모델이 항상 좋은 모델은 아니다.

03 보지 않은 데이터에서도 잘 작동하는 모델이 좋은 모델이다.

Generalization