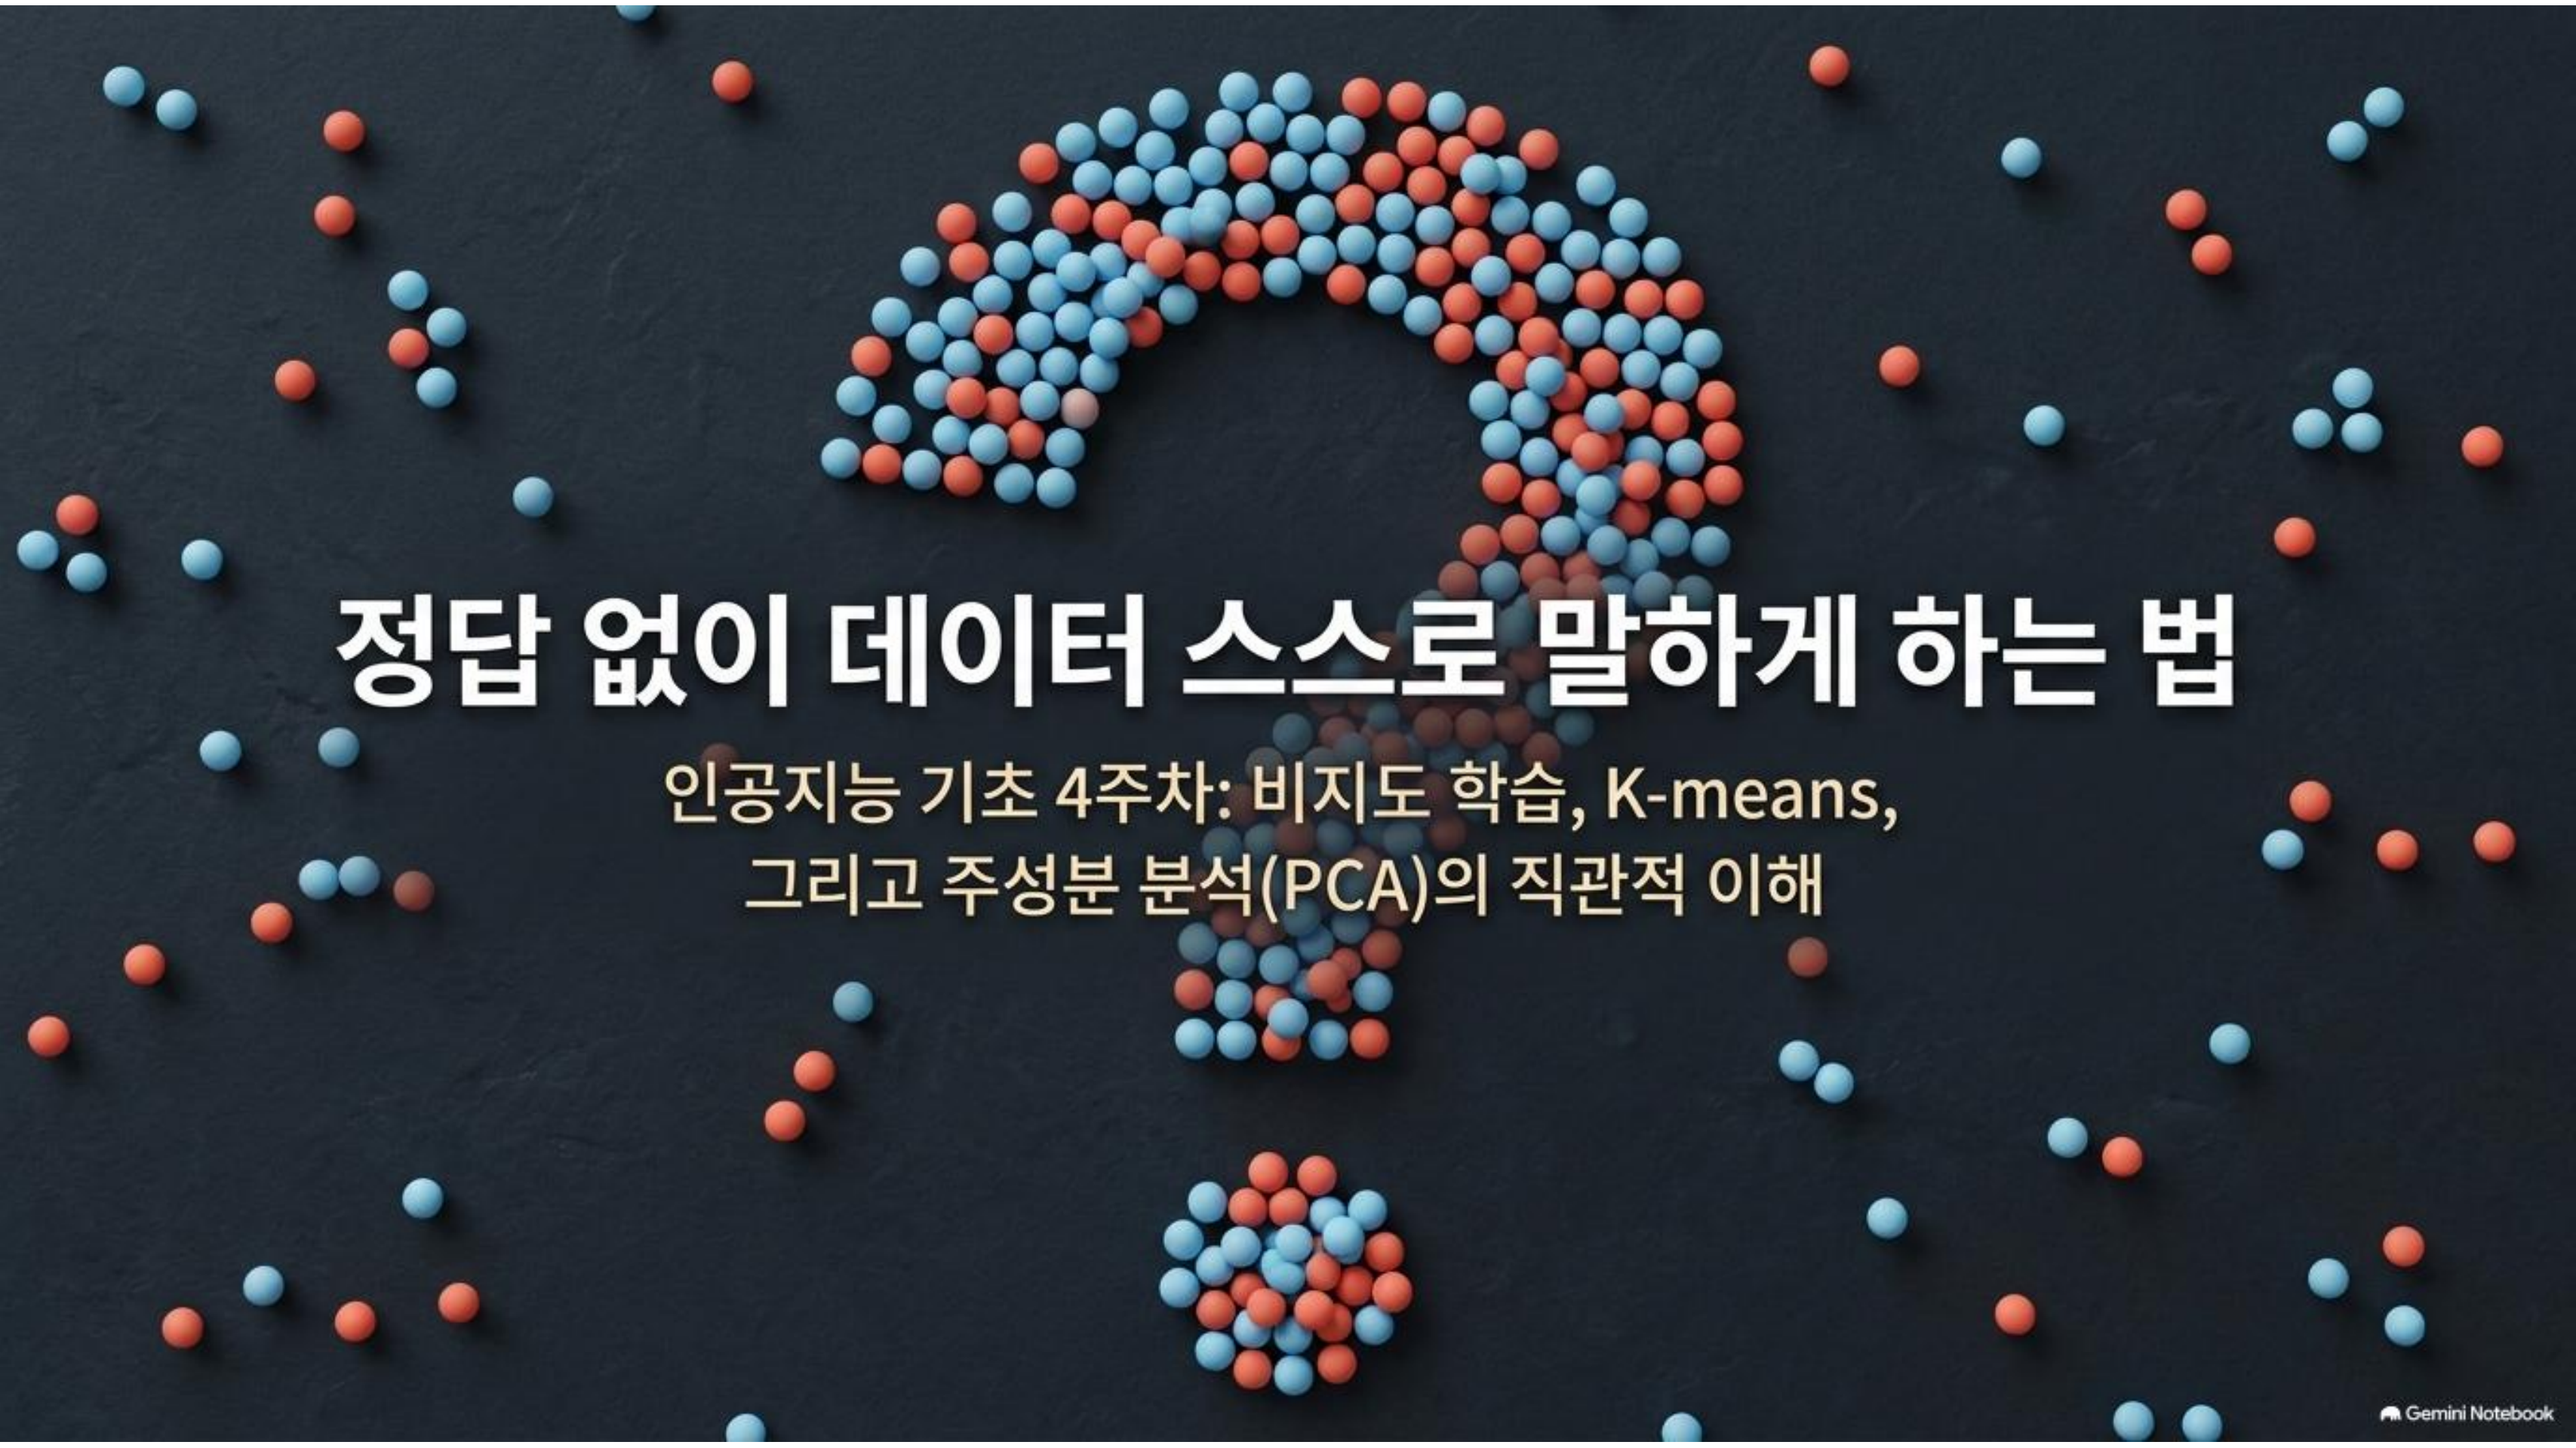
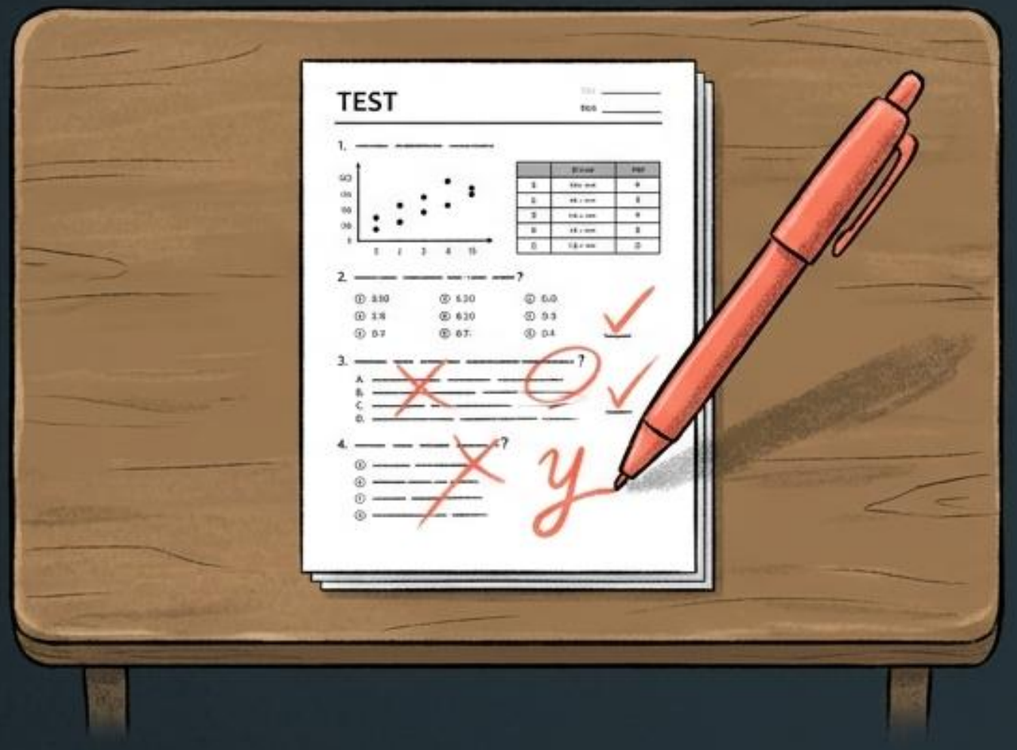

정답 없이 데이터 스스로 말하게 하는 법
인공지능 기초 4주차: 비지도 학습, K-means,
그리고 주성분 분석(PCA)의 직관적 이해
Gemini Notebook

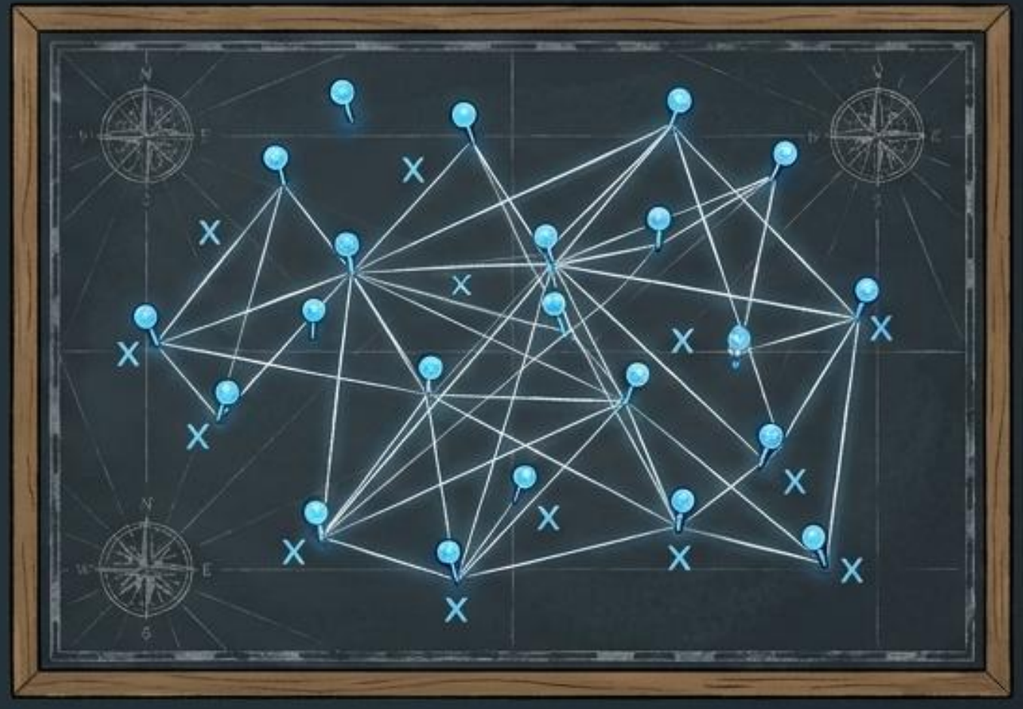
학습의 패러다임이 '관계'에서 '내부 구조'로 바뀝니다

지도학습: 예측과 정답의 차이



정답과의 오차(Error)를 줄이는 훈련

비지도학습: 데이터 내부의 구조 탐색



데이터 내부의 거리와 분산(Structure)을 최적화하는 탐험

Gemini Notebook

캄캄한 공간에서 우리가 찾아낼 수 있는 네 가지 구조



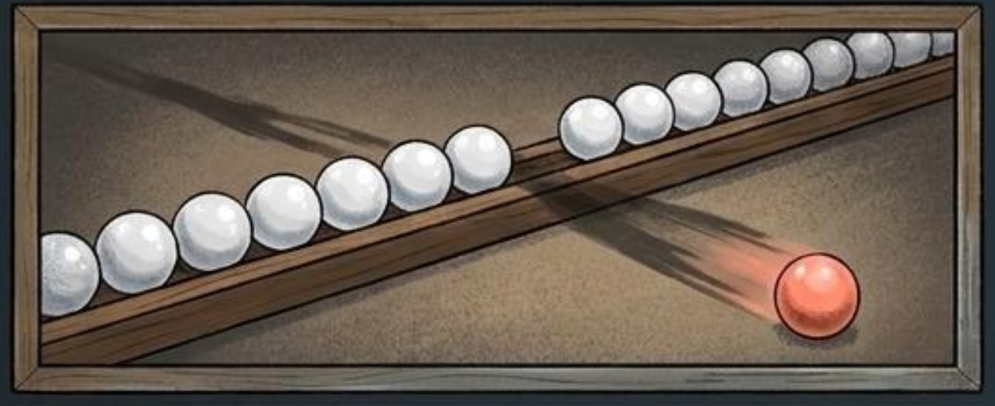
고객 세분화

구매 패턴이 비슷한 고객군 묶기



문서 탐색

내용이 비슷한 문서들의 군집화



이상 탐지

정상 패턴에서 멀리 떨어진 사례 찾기



시각화

수백 개의 특징을 2차원 지도로 요약하기

Gemini Notebook

제1장. 끼리끼리 모이다: K-means 알고리즘



거리 + 반복 = 군집 내부의 최적화

각 점을 가까운 중심에 배정하고,
중심을 다시 계산한다.

Gemini Notebook

탐험을 시작하기 전, 세 가지 규칙을 정해야 합니다

K (군집의 개수)

운동장에 몇 개의 깃발을 꽂을 것인가?



거리 (가까움의 기준)

어떤 길을 따라 걸을 것인가?



초기 중심 (출발점)

첫 깃발을 어디에 던질 것인가?



Gemini Notebook

운동장 깃발 비유: 군집이 완성되는 4단계 라이프사이클



Gemini Notebook

비지도 학습도 결국 '손실(Loss)'을 줄이는 과정입니다



지도학습의 손실

예측값과 정답
사이의 오차

비지도학습의 손실

데이터와 군집 중심 사이의
'거리(텐션)'

K-means는 이 고무줄들의 전체 장력이 최소화되는 가장 편안한 상태를 찾는 최적화 과정입니다.

Gemini Notebook

K가 달라지면, 데이터가 들려주는 이야기도 달라집니다



손실은 K가 커질수록 무조건 줄어듭니다. 하지만 '수학적 최적'이 항상 '현실의 정답'은 아닙니다. 도메인 지식을 통한 해석이 필수적입니다.

Gemini Notebook

제2장. 텅 빈 공간의 공포: 차원의 저주



특징(Feature)이 많을수록,
인공지능은 더 잘 배울 수 있을까요?

Gemini Notebook

골목길에서 우주로: 차원이 늘면 이웃이 사라집니다

1차원 (골목길)



필요 격자: 10^1.
닿을 듯 가까운 이웃.

2차원 (광장)



필요 격자: 10^2.
100명이면 다시 구조가 보임.

고차원 (우주)



필요 격자: 10^100.
공간이 너무 방대하여
모두가 홀로 고립됨.

Gemini Notebook

잡음 특징은 모델을 '융통성 없는 암기생'으로 만듭니다

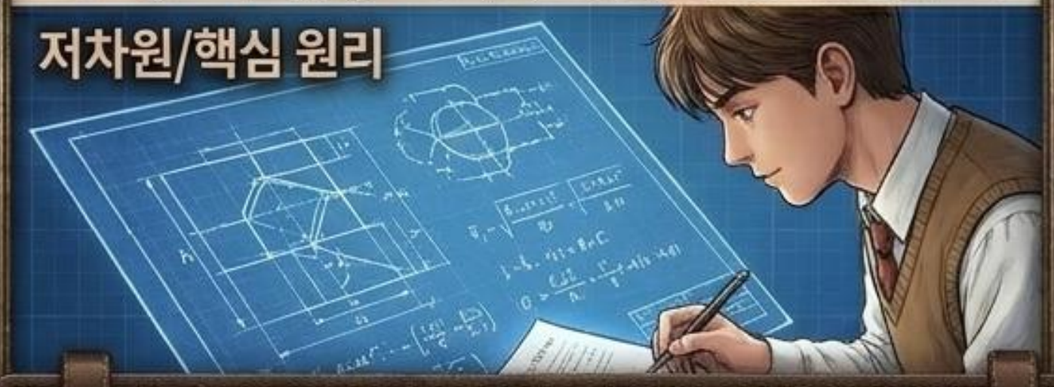
고차원: 거리 개념의 붕괴



최근접 거리와 최원 거리의 차이가
희미해져 '누가 더 가까운가' 판단 불가

잡음에 집중하는 과적합(Overfitting)





새로운 문제(Test data)에서 흔들리는
모델 vs 원리를 파악한 일반화 모델

Gemini Notebook

제3장. 본질을 투영하다: 주성분 분석(PCA)





PCA는 불필요한 차원을 버리고, 데이터의 정보(분산)를
가장 많이 담아내는 '새로운 축'을 찾는 과정입니다.

Gemini Notebook

그림자 비유: 어느 각도에서 비춰야 본질이 보일까요?

일반 변수 축 (나쁜 각도)



특징이 뭉개진 둥근 그림자 (낮은 분산).
새인지 공인지 알 수 없음.

제1주성분 축 (최적의 각도)



형태가 완벽하게 보존된
넓은 그림자 (가장 큰 분산).

데이터가 가장 넓게 퍼지는 방향(=분산이 최대화되는 축)이 곧 정보 손실이 가장 적은 최적의 투영 좌표입니다.

Gemini Notebook

빛과 그림자의 선형대수학



공분산 행렬: 3D 허공에 떠 있는
데이터 구름 자체의 입체적인 모양

$$\Sigma \mathbf{v} = \lambda \mathbf{v}$$



고유값: 그림자가 쫙 퍼진 넓이
(그 축이 설명하는 분산의 크기)



고유벡터: 빛을 비추는 '최적의 각도'
(새로운 축의 방향)

가장 큰 λ(고유값)를 가지는 $\mathbf{v}$(고유벡터)가 바로 제1주성분(PC1)이 됩니다.

Gemini Notebook

PCA를 적용하는 4단계 파이프라인



1. 중심화 및 표준화

데이터를 원점(0,0)으로
옮기고 찌그러진
스케일 맞추기



2. 공분산 계산

특징들이 어떻게
함께 변하는지
입체적 구조(Σ) 파악



3. 축 선택

빛을 비출 최고의
각도(고유벡터)를
고유값이 큰 순서대로 정렬

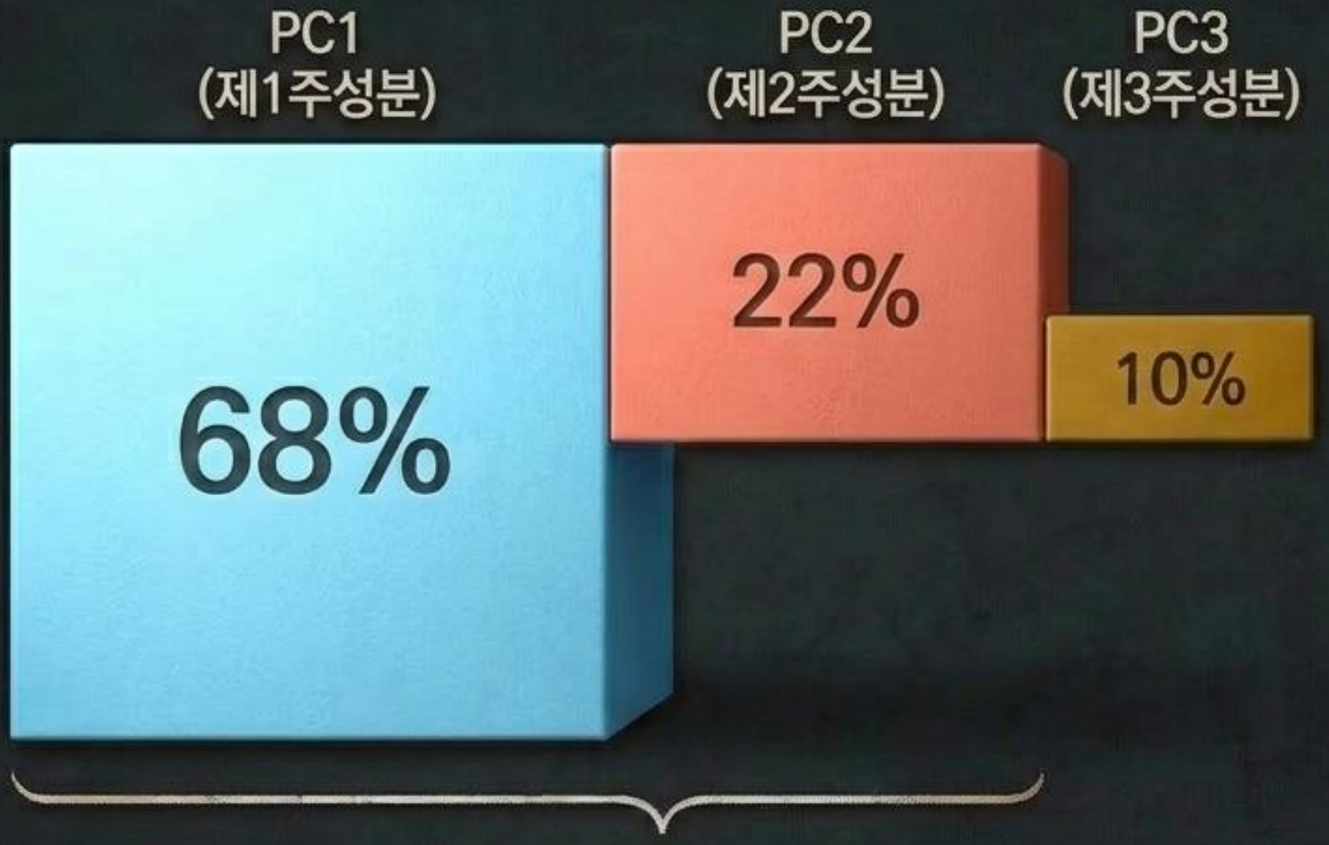


4. 투영 (Transform)

원래의 데이터를 선택한
2D 캔버스(새 좌표)로
눌러 찍기

Gemini Notebook

분산이 큰 축이 더 많은 데이터를 설명합니다



PC1 + PC2 = 단 2개의 새로운 축만으로도
전체 정보(분산)의 90% 보존 완료

Gemini Notebook

제4장. 현실 세계의 함정: 단위와 누출

알고리즘은 훌륭하지만,
들어가는 데이터가 왜곡되면
결과도 왜곡됩니다.

Gemini Notebook

함정 1. 단위에 지배당한 알고리즘 (코끼리와 쥐)

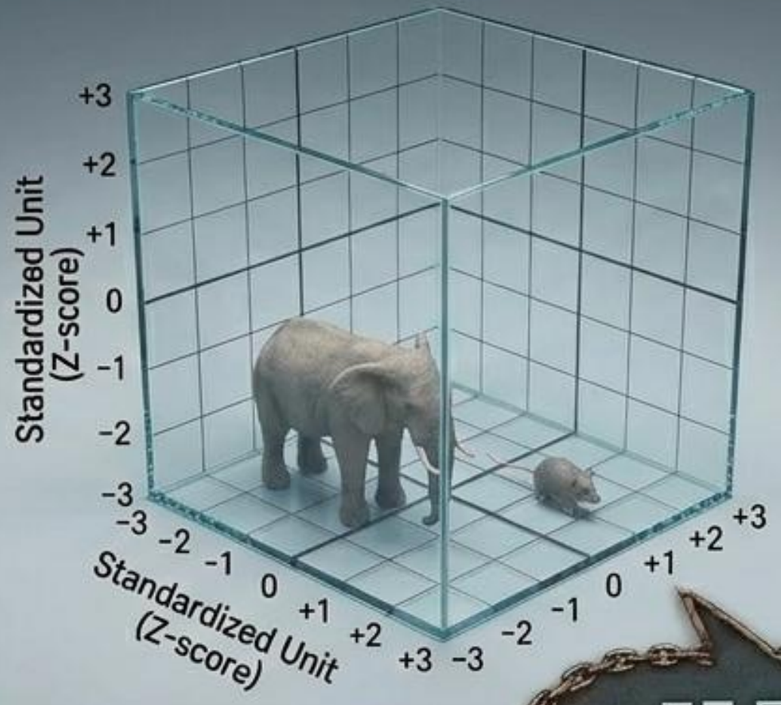
단위 왜곡: kg vs mm



꼬리 길이는 무시되고
숫자가 큰 몸무게 단위에
알고리즘이 지배당함

꼬리 길이는 무시되고
숫자가 큰 몸무게 단위에
알고리즘이 지배당함

공정한 기준 (Standardization)

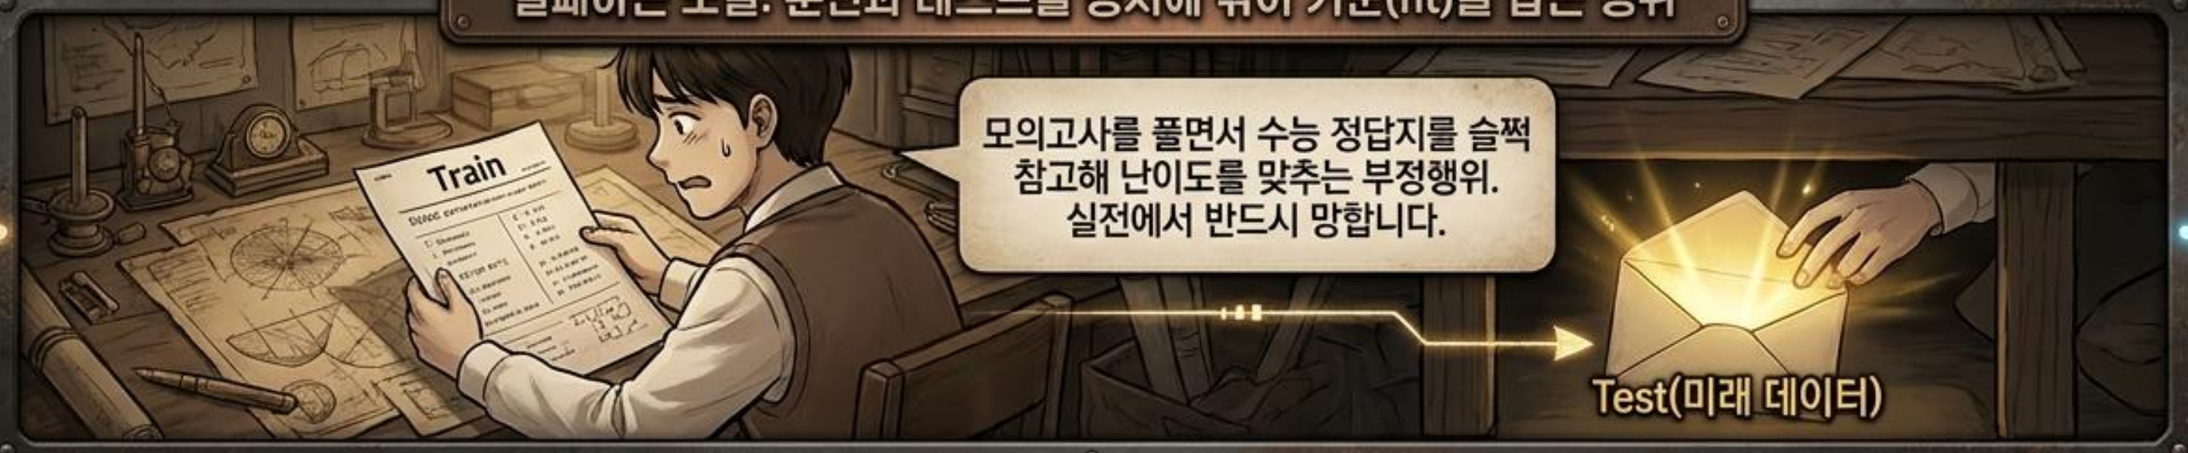


모든 특징이
동등한 잣대 위에서
공정한 거리 계산 가능

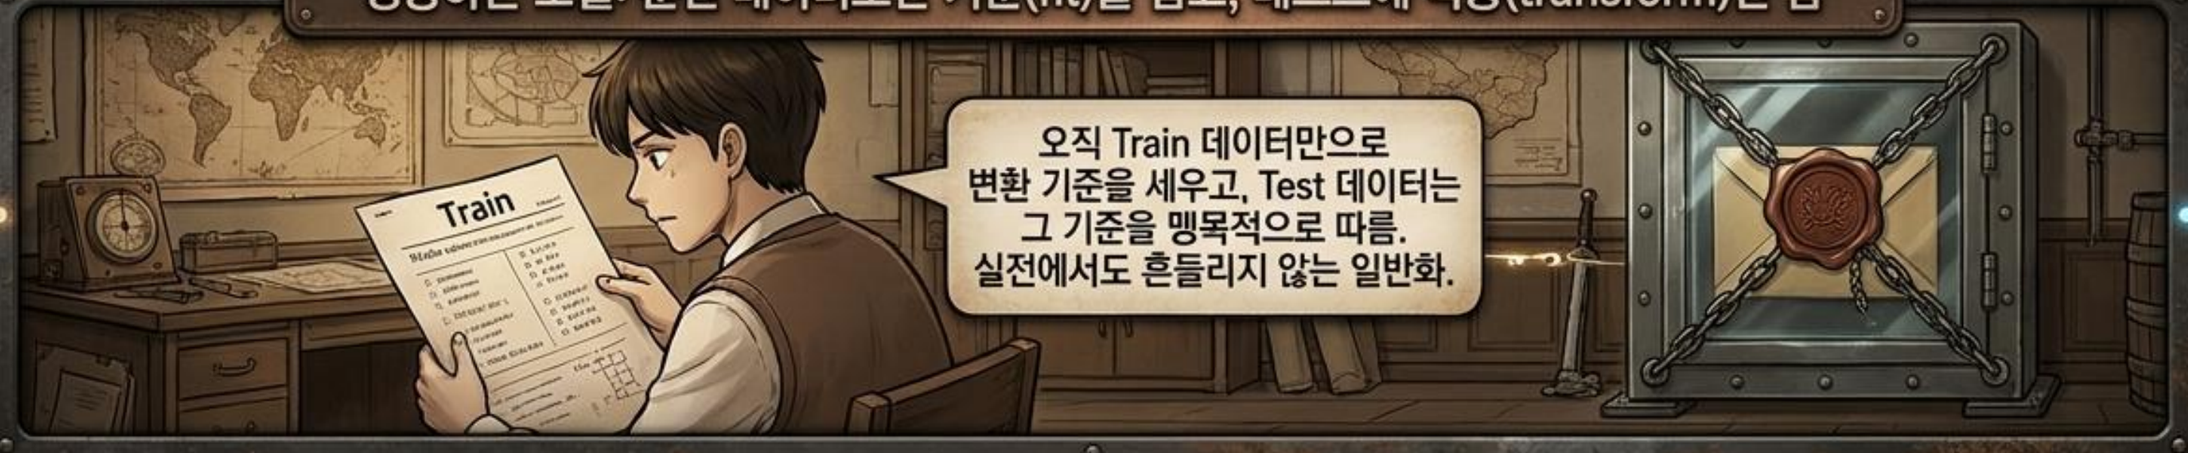
Gemini Notebook

함정 2. 미래를 훔쳐보는 죄 (데이터 누출, Data Leakage)

실패하는 모델: 훈련과 테스트를 동시에 섞어 기준(fit)을 잡는 행위



성공하는 모델: 훈련 데이터로만 기준(fit)을 잡고, 테스트에 적용(transform)만 함



Gemini Notebook

종합: 비지도 학습도 '학습의 기본 원리' 안에 있습니다

	[지도학습]	[비지도학습]
학습 대상	X와 y의 관계	X 내부의 구조
손실(Loss)	예측과 정답의 차이	데이터와 중심의 거리
매개변수	회귀계수 / 가중치(Weight)	군집 중심 / 주성분 축
일반화 목표	새로운 데이터의 예측	안정적이고 유용한 구조 도출

정답(y)이 없다는 것뿐, 비지도 학습 역시 목적함수와 최적화라는
AI의 거대한 법칙 안에서 완벽하게 작동합니다.

Gemini Notebook

본질을 남기고 복잡성을 줄이는 여정




```
> Next Lab: Python Code
> 1. StandardScaler() 적용
> 2. KMeans() 군집화
> 3. PCA() 시각화 및 결과 해석

실습 동영상에서 뵙겠습니다.
```

Gemini Notebook