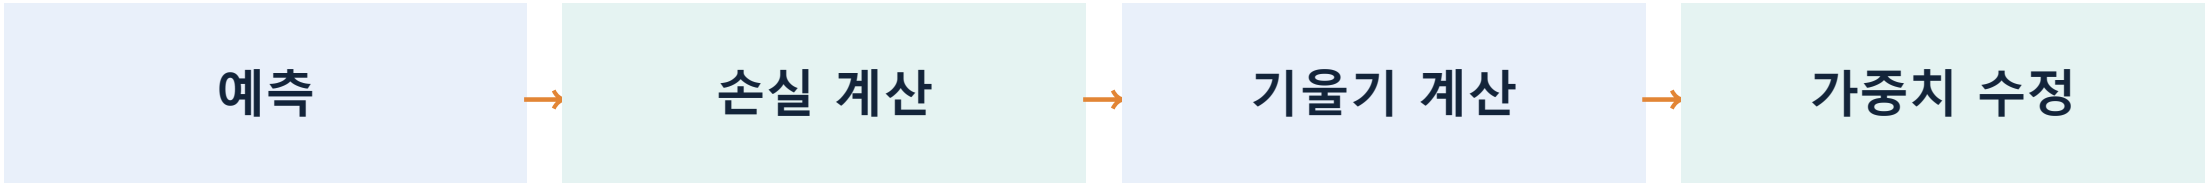
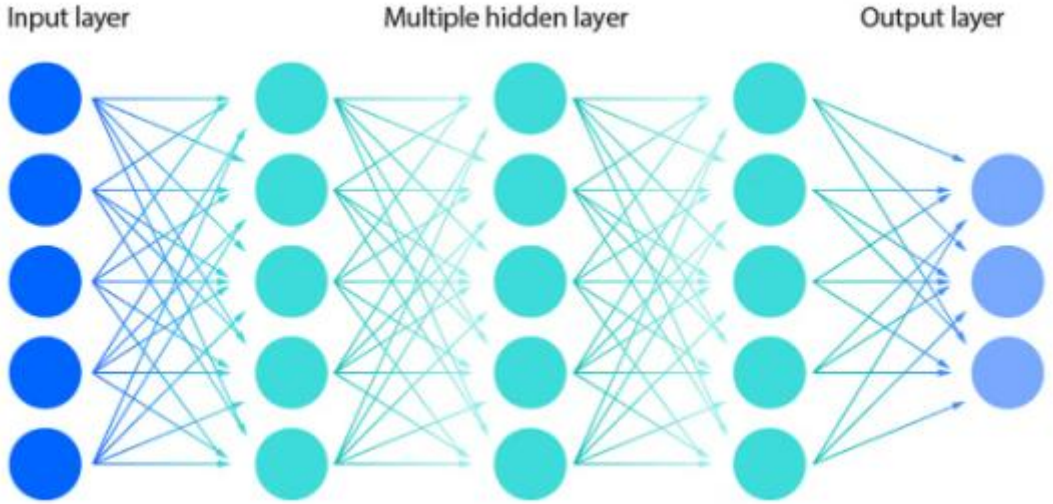
미분의 연쇄 법칙과 신경망 학습 안정화

다층 퍼셉트론은 어떻게 가중치를 스스로 고칠까?



오늘의 학습 목표



강의가 끝나면 설명할 수 있는 세 가지

역전파 · 기울기 소실 · 학습 안정화

① 연쇄 법칙으로 각 가중치의 기울기를 구한다.
② 깊은 층에서 기울기가 작아지는 이유를 설명한다.
③ 활성화 함수, 초기화, 최적화, 규제화의 역할을 구분한다.

학습의 세 질문

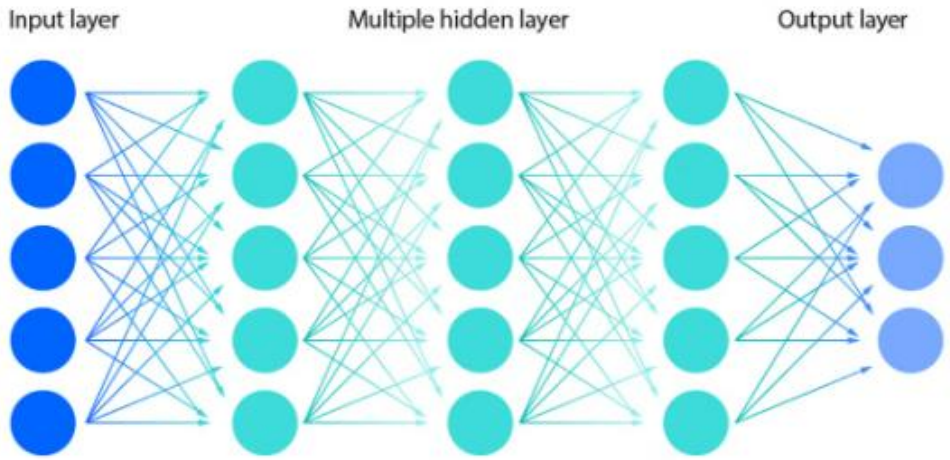
어떻게 계산? → 왜 작아지나? → 어떻게 안정화?

학습은 가중치를 조정하는 과정

입력 x → 예측 $\hat{y}$ → 정답 y와 비교 → 가중치 수정

같은 입력에도 가중치가 바뀌면 예측값이 달라진다.

목표: 처음 보지 않은 데이터에서도 예측 오차를 줄이기



손실 함수는 예측 오류를 숫자로 표현

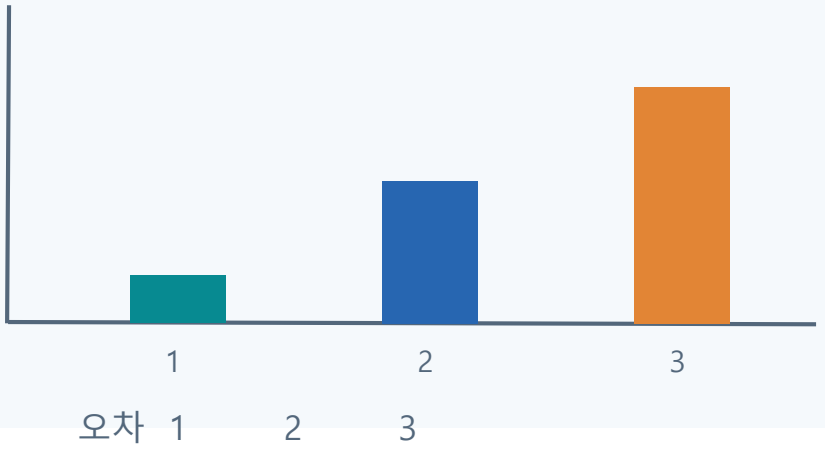
회귀와 분류에는 서로 다른 손실을 쓴다

모델이 얼마나 틀렸는가?

$$MSE = (1/n)\ \Sigma(y_i - \hat{y}_i)^2$$

MSE: 실제값과 예측값의 차이를 제곱하여 평균
교차 엔트로피: 정답 범주에 준 확률이 낮을수록 큰 벌점

예측 오차가 커지면 손실도 증가



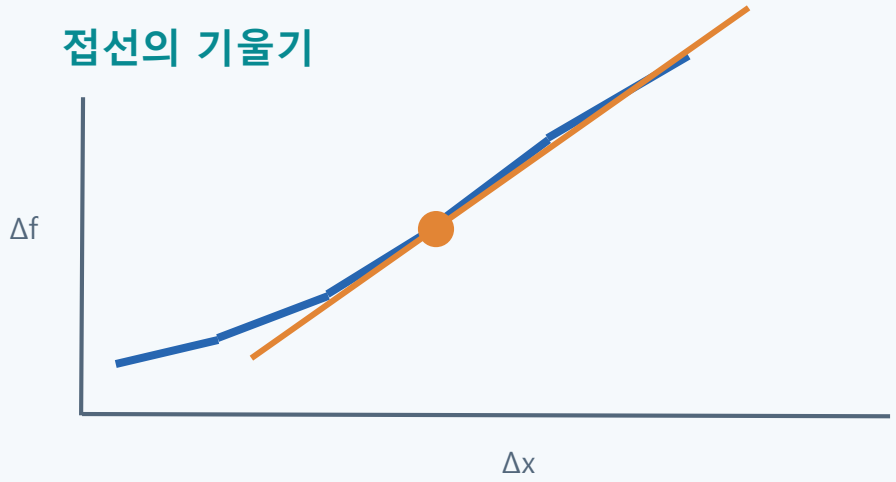
미분은 작은 변화에 대한 반응

입력값을 조금 바꾸어 본다

기울기 = 출력 변화 ÷ 입력 변화

$$f'(x) \approx [f(x + \Delta x) - f(x)] / \Delta x$$

양수 기울기: x를 올리면 함수값 증가
음수 기울기: x를 올리면 함수값 감소



경사하강법으로 가중치 수정

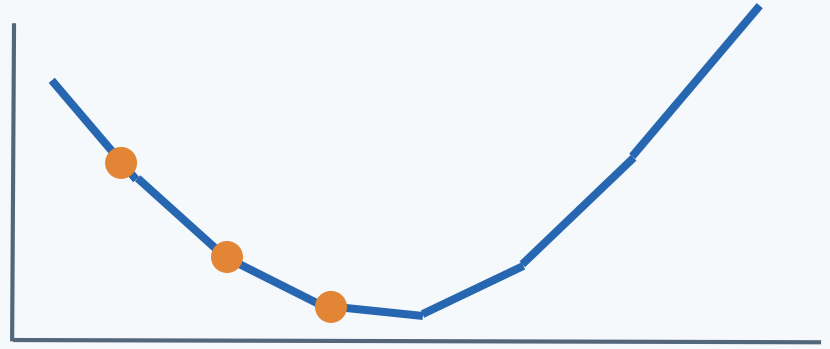
기울기 반대 방향으로 한 걸음

현재 손실에서 낮아지는 방향 찾기

$$w_{new} = w_{old} - \eta \cdot \partial L / \partial w$$

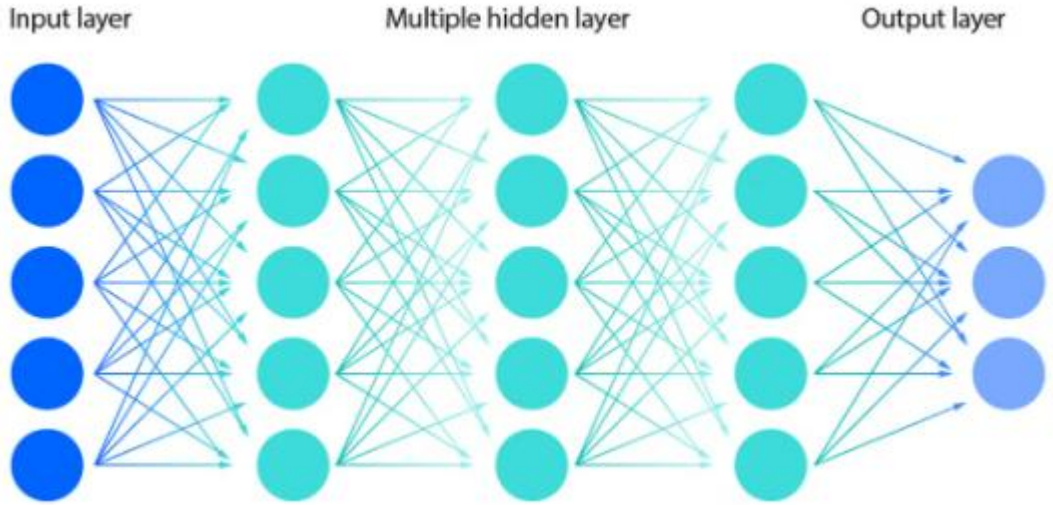
η는 학습률이다. 너무 크면 최솟값을 지나칠 수 있고, 너무 작으면 학습이 느리다.

손실 곡선 위의 작은 걸음



기울기 반대 방향으로 이동

첫 층의 가중치가 손실에 미치는 영향



첫 가중치 w → 은닉층 h → 예측 $\hat{y}$ → 손실 L

질문: w를 아주 조금 바꾸면 최종 손실 L은 얼마나 변할까?

합성함수와 연쇄 법칙

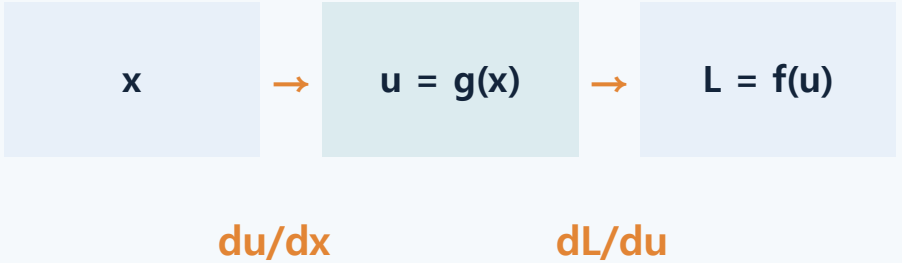
출력이 다시 다음 함수의 입력이 된다

$$x \rightarrow u = g(x) \rightarrow L = f(u)$$

$$\frac{dL}{dx} = \frac{dL}{du} \cdot \frac{du}{dx}$$

전체 변화율은 경로를 따라 단계별 변화율을 곱한다.
예: x가 u에 미치는 영향 × u가 L에 미치는 영향

변수 사이의 영향



연쇄 법칙 계산 예시

숫자로 확인하기

$$u = 3x,\ L = u^2$$

$$\frac{dL}{dx} = 2u \cdot 3 = 6u = 36$$

x=2라면 u=6, dL/du=12, du/dx=3
따라서 dL/dx=36. 직접 계산한 $L=9x^2$의 도함수 18x와 같다.

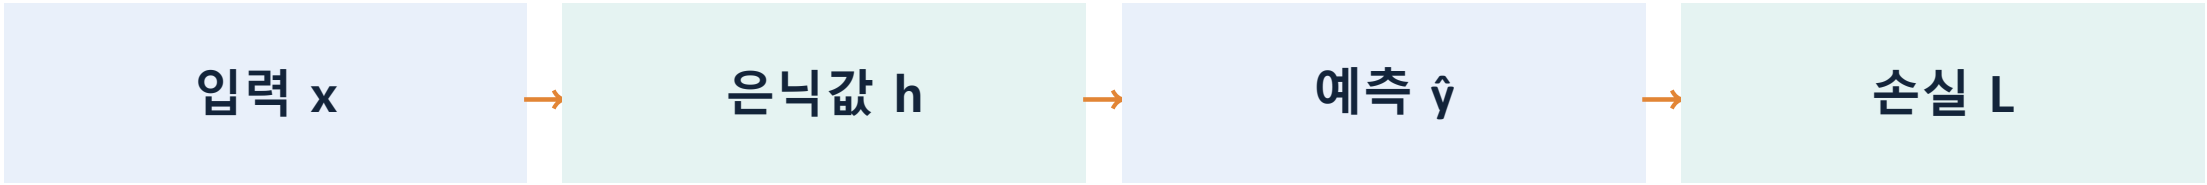
x = 2 에서 값과 기울기

x = 2	→	u = 6	→	L = 36

× 3 × 12

3 × 12 = 36

순전파와 역전파



순전파: 왼쪽에서 오른쪽으로 값을 계산

역전파: 오른쪽에서 왼쪽으로 손실의 기울기를 계산

한 개 은닉 뉴런의 역전파

$$z = wx + b \rightarrow h = \sigma(z) \rightarrow \hat{y} = vh \rightarrow L(\hat{y}, y)$$

첫 가중치 w의 기울기

$$\partial L/\partial w = (\partial L/\partial \hat{y})(\partial \hat{y}/\partial h)(\partial h/\partial z)(\partial z/\partial w)$$