인공지능기초 · 7주차

깊은 신경망,
어떻게 잘 배우게 할까?

역전파로 구한 기울기를 '제대로' 쓰기 위한 세 가지 도구

① 기울기 소실 막기

② 더 똑똑하게 내려가기

③ 외우지 않고 이해하게

지난주 복습

역전파: 손실에서 출발해 기울기를 뒤로 보낸다

STEP 1
예측
순전파로 출력 계산

→

STEP 2
손실 계산
정답과 얼마나 다른가

→

STEP 3
기울기 계산
연쇄 법칙으로 뒤로

→

STEP 4
가중치 수정
$w \leftarrow w - \eta \cdot \partial L/\partial w$

오늘의 질문

층이 깊어져도 이 네 단계가 **'실제로'** 잘 돌아가려면 무엇이 필요할까?

오늘의 지도

학습이 막히는 세 가지 지점과 해결책

PART 1

기울기 소실

문제: 앞쪽 층까지 학습 신호가 닿지 않는다

해결: ReLU, 가중치 초기화

PART 2

최적화

문제: 손실이 흔들리거나 너무 느리게 준다

해결: 모멘텀, RMSprop, Adam

PART 3

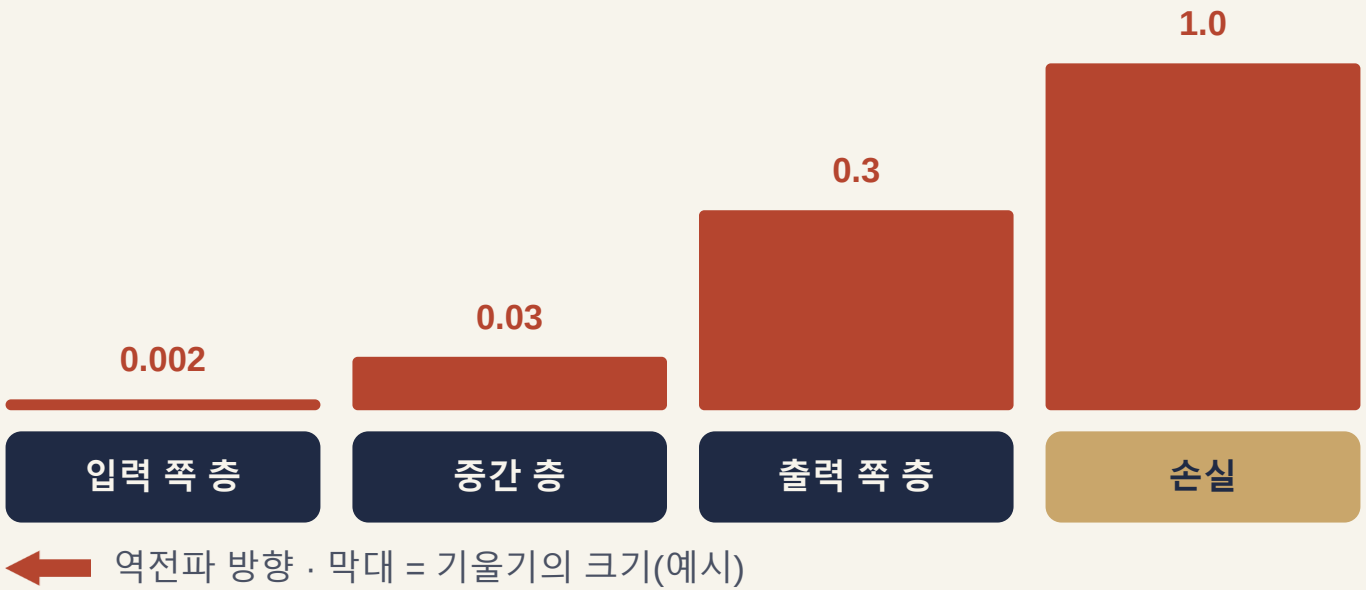
규제화

문제: 훈련 자료만 외우고 새 자료는 못 푼다

해결: L1·L2, 드롭아웃, 조기 종료

PART 1 · 기울기 소실

뒤에서 보낸 신호가 앞에 닿지 않는다



귓속말 전달 게임

줄이 길수록 맨 앞사람에게는 말이 희미하게 도착한다.

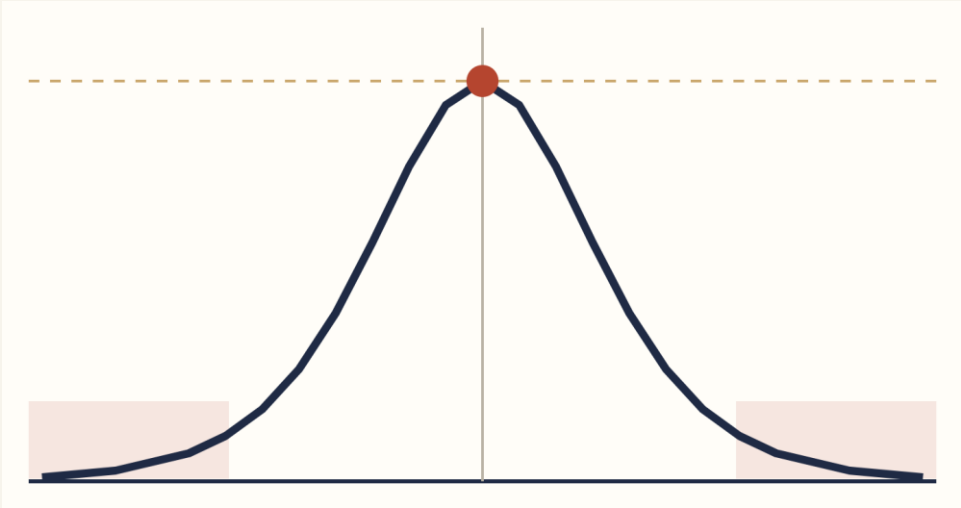
결과

기울기가 작으면 수정량 η·g도 작다 → 앞쪽 층은 거의 배우지 못한다

PART 1 · 기울기 소실

범인: 시그모이드의 기울기는 최대 0.25

σ′(z) 그래프 · 꼭대기 = 0.25 (z = 0)



z가 매우 작으면 ≈ 0

z가 매우 크면 ≈ 0

$$\sigma'(z) = \sigma(z) \cdot [1 - \sigma(z)]$$

왜 0.25인가?

σ(z)는 0과 1 사이. 두 수 a와 (1 − a)의 곱은 a = 0.5일 때 가장 크다.

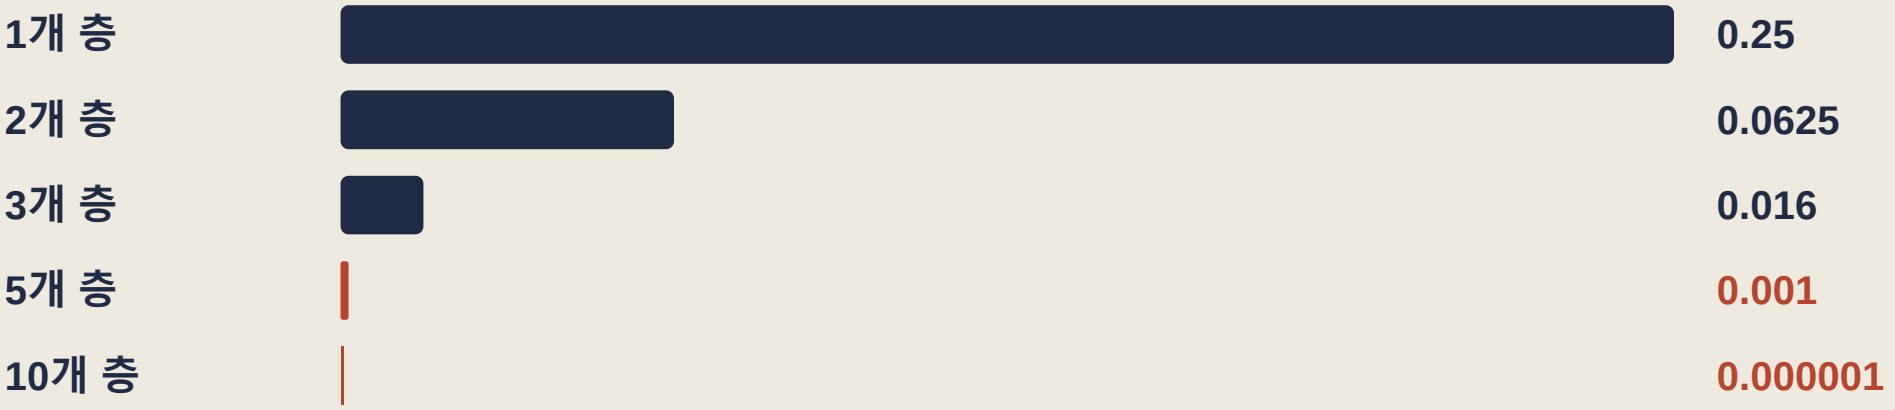
0.5 × 0.5 = 0.25

포화 구간

출력이 0이나 1에 붙으면 기울기는 거의 0. 뉴런이 '확신'할수록 배우지 못한다.

PART 1 · 기울기 소실

0.25를 층마다 곱하면 무슨 일이?

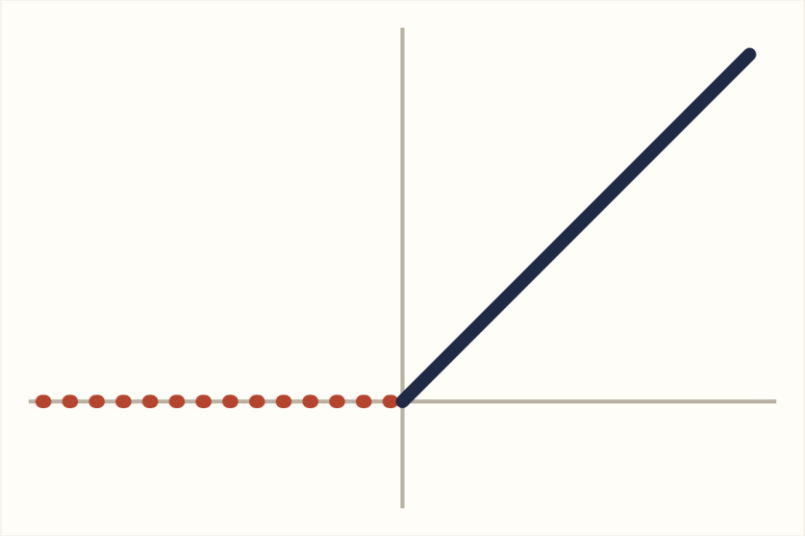


10층이면 앞쪽 층의 기울기는 **약 100만 분의 1** — 최댓값으로 계산해도 이렇다

주의: 실제 기울기에는 가중치의 크기와 여러 경로의 합도 곱해진다. 그래서 다음 해법은 **활성화 함수**와 **가중치 초기화** 두 갈래다.

PART 1 · 해결책 ①

ReLU: 양수 구간에서는 신호를 깎지 않는다



z < 0 : 기울기 0

z > 0 : 기울기 1

ReLU(z) = max(0, z)

장점: 기울기 1을 그대로 통과

시그모이드 최대 0.25 vs ReLU 1. 층을 쌓아도 활성화 함수 때문에 줄지 않는다. 계산도 매우 빠르다.

주의: 죽은 ReLU

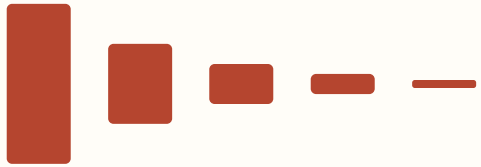
입력이 계속 음수면 기울기가 0 → 그 뉴런은 영영 멈출 수 있다. 보완: Leaky ReLU (음수 쪽에 작은 기울기)

PART 1 · 해결책 ②

가중치 초기화: 출발점이 신호의 운명을 정한다

층을 지날 때 신호의 폭 (1층 → 5층)

너무 작음



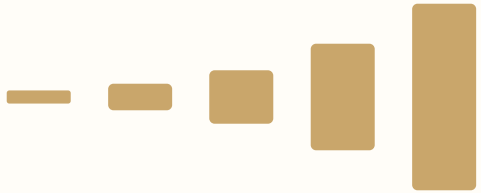
사라짐

적절함



유지됨

너무 큼



폭발

목표: 층을 지나도 신호의 **분산**이 크게 변하지 않게

Xavier 초기화

시그모이드 · tanh 계열

Var(w) = 2 / (n_in + n_out)

He 초기화

ReLU 계열

Var(w) = 2 / n_in

PART 2 · 최적화

SGD: 안개 낀 산에서 발밑만 보고 내려가기

$$w_{t+1} = w_t - \eta \cdot g_t$$

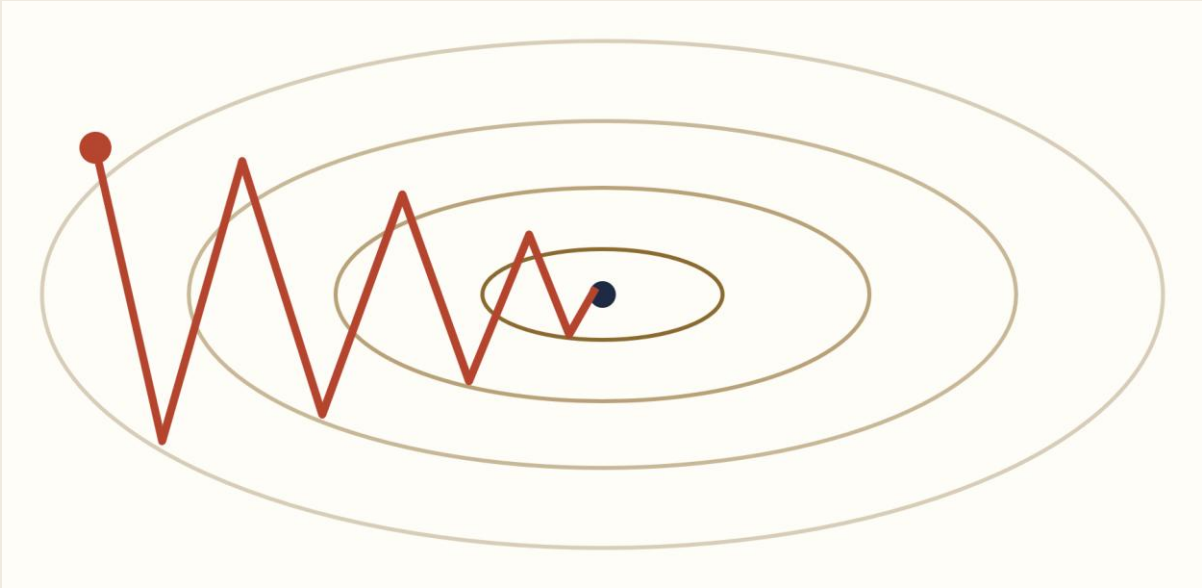
- 손실 = 산의 높이, 가중치 = 지금 위치
- 기울기 g = 발밑의 경사, 학습률 η = 보폭
- 미니배치 = 매번 일부 자료만 보고 경사를 짐작
- 그래서 방향이 매번 **조금씩 흔들린다**

비교	전체 배치	미니배치 SGD
한 걸음 계산량	매우 큼	작음
방향의 정확도	정확	흔들림
같은 시간 걸음 수	적음	많음
얕은 골 탈출	어려움	흔들림이 도움

흔들림은 단점이자 장점. 문제는 '나쁜 흔들림' — 다음 장

PART 2 · 최적화

SGD가 고전하는 두 가지 지형



빨간 선: SGD 경로 · 검은 점: 최저점

좁고 긴 골짜기

가파른 벽 쪽으로 왔다 갔다, 정작 골짜기 방향으로는 조금씩만 전진

평지 · 안장점

경사가 거의 0 → 보폭이 거의 0. 최저점이 아닌데도 멈춘 듯 느려짐

PART 2 · 최적화

모멘텀: 굴러가는 공처럼 관성을 더한다

$$v_t = \beta \cdot v_{t-1} + g_t$$

$$w_{t+1} = w_t - \eta \cdot v_t$$

β = 0.9 → 이전 속도의 90%를 기억

같은 방향이 이어지면 → 가속

단계	1	2	3	4
기울기 g	+1	+1	+1	+1
속도 v	1.00	1.90	2.71	3.44

완만한 골짜기 방향으로 점점 빨라진다

방향이 번갈아 바뀌면 → 상쇄

단계	1	2	3	4
기울기 g	+1	−1	+1	−1
속도 v	1.00	−0.10	0.91	−0.18

지그재그 성분은 서로 지워져 흔들림이 준다

PART 2 · 최적화

Adagrad · RMSprop: 변수마다 보폭을 다르게

많이 움직인 변수는 **보폭을 줄이고**, 거의 안 움직인 변수는 **보폭을 키운다** · $w \leftarrow w - \eta \cdot g / \sqrt{s}$

Adagrad · 전부 기억하는 일기장

$$s_t = s_{t-1} + g_t^2$$

과거 기울기 제곱을 계속 더함 → s는 커지기만 → 보폭이 0에 가까워져 학습이 멈출 수 있다



RMSprop · 최근 메모장

$$s_t = \rho \cdot s_{t-1} + (1 - \rho) \cdot g_t^2$$

최근 기울기 제곱의 이동평균($\rho \approx 0.9$) → 오래된 기억은 희미해짐 → 보폭이 계속 살아 있다



PART 2 · 최적화

Adam = 모멘텀(방향) + RMSprop(보폭)

① 방향 기억 (모멘텀)

$$m_t = \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$$

기울기의 평균적 방향

+

② 크기 기억 (RMSprop)

$$v_t = \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$$

기울기 크기의 평균적 규모

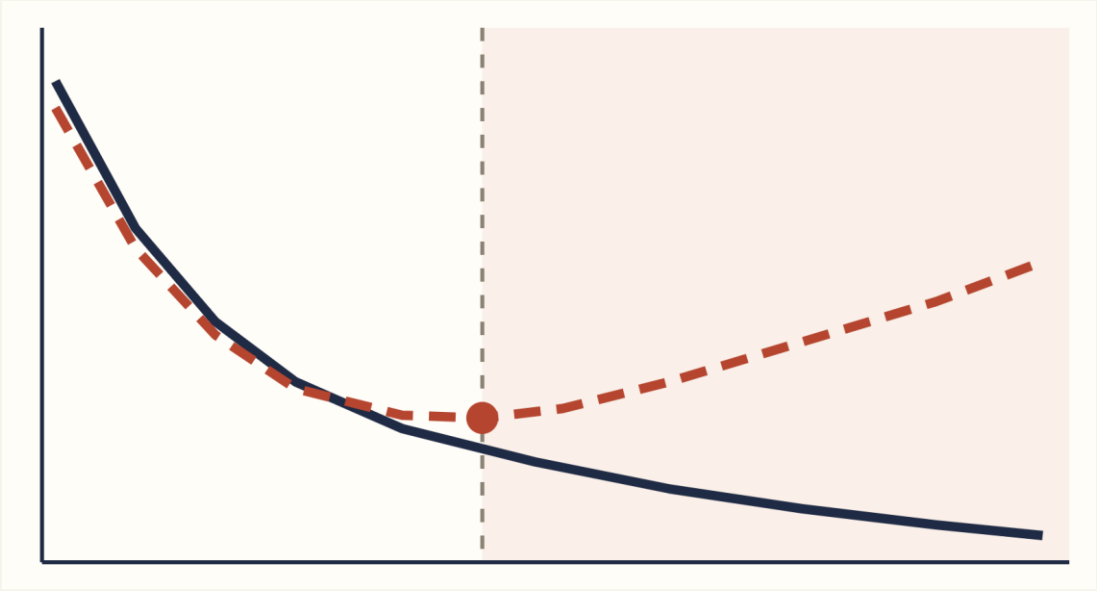
③ 수정 $w \leftarrow w - \eta \cdot \hat{m} / (\sqrt{\hat{v}} + \varepsilon)$ $\hat{m}, \hat{v}$: 초반에 0에서 출발한 값을 보정한 것

기본값	의미
$\eta = 0.001$	기본 보폭
$\beta_1 = 0.9, \beta_2 = 0.999$	방향·크기 기억의 길이

가장 많이 쓰는 **좋은 출발점**. 하지만 모든 문제에서 최고는 아니다.

PART 3 · 규제화와 과적합

과적합: 기출문제 답만 외운 학생



— 훈련 손실 (실선) □ 검증 손실 (점선) 가로축: 에폭

점선 왼쪽: 함께 배우는 중

두 손실이 같이 내려간다 = 일반적인 규칙을 배우고 있다

점선 오른쪽: 외우기 시작

훈련 손실 ↓, 검증 손실 ↑ = 훈련 자료의 우연한 패턴까지 맞추는 중

그래서 자료를 훈련·검증으로 나누고, 검증 손실을 계속 지켜본다

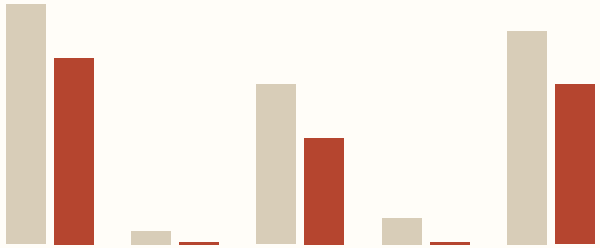
PART 3 · 해결책 ①

L1 · L2 규제: 큰 가중치에 벌점을 매긴다

전체 목표 = 원래 손실 + λ · 규제 항 λ가 클수록 단순한 모델 쪽으로 강하게 끌어당긴다

L1 규제 λ · Σ|w|

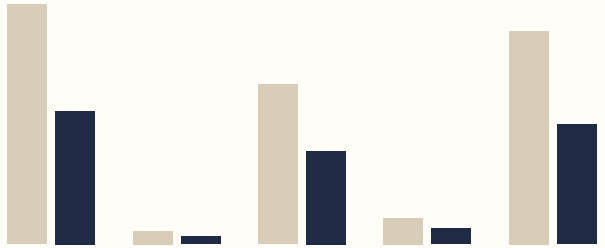
덜 중요한 가중치를 **정확히 0**으로 → 필요 없는 특징을 지운다



연한 = 규제 전 · 진한 = 규제 후 · w_2, w_4 → 0

L2 규제 λ · Σw²

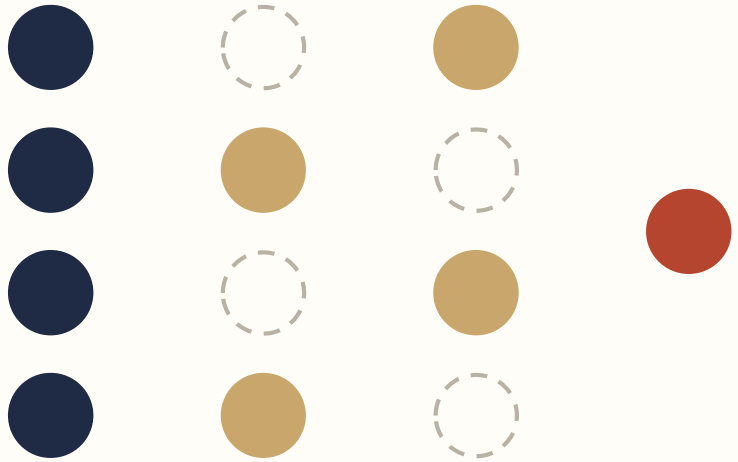
모든 가중치를 **고르게 작게** → 한 특징에 과하게 기대지 않는다



모두 작아지지만 0은 아님 · ‘weight decay’

PART 3 · 해결책 ②

드롭아웃: 훈련 때마다 일부 뉴런을 쉬게 한다



점선 원 = 이번 단계에서 꺼진 뉴런 (p = 0.5)

훈련 중

매 단계 무작위로 일부 뉴런의 출력을 0으로. 매번 다른 '작은 신경망'이 학습된다

테스트 · 실제 사용

모든 뉴런을 켠다. 여러 작은 신경망의 의견을 모은 효과

팀 프로젝트 비유: 아무나 결석할 수 있으면, 모두가 전체 내용을 이해하게 된다

PART 3 · 해결책 ③

조기 종료: 나빠지기 시작하면 멈춘다

에폭	검증 손실	판단 (patience = 3)
1	0.62	최저 갱신
2	0.48	최저 갱신
3	0.41	최저 갱신
4	0.39	최저 갱신 → 가중치 저장
5	0.40	개선 없음 1회
6	0.42	개선 없음 2회
7	0.41	개선 없음 3회 → 중단

patience (인내심)

한두 번 흔들려도 바로 멈추지 않고 몇 번 더 기다린다

최고 가중치 복원

마지막(7)이 아니라 가장 좋았던 에폭 4의 가중치를 쓴다

정리 · 실습 연결

학습 로그로 보는 증상과 처방

증상 (loss 그래프 · 로그)	의심 원인	처방
앞쪽 층 기울기 ≈ 0, loss가 거의 안 줄어듦	기울기 소실	ReLU 계열 + He 초기화
loss가 갑자기 커지거나 NaN	기울기 폭발	학습률 ↓, 초기화 점검
loss가 크게 들쭉날쭉, 느리게 감소	보폭·방향 문제	모멘텀 · Adam, 학습률 조정
훈련 loss ↓ 인데 검증 loss ↑	과적합	L2 · 드롭아웃 · 조기 종료

이번 주 실습 ‘디버깅 튜터’ — 내 학습 로그를 생성형 AI에 보여 주고 원인을 진단받은 뒤, 위 표와 비교해 직접 검증한다

7주차 핵심 정리

기울기를 구하고, 전달하고, 잘 쓰고, 지나치지 않게

6주차
연쇄 법칙
기울기 계산

→

Part 1
ReLU · 초기화
신호 유지

→

Part 2
Adam
가중치 수정

→

Part 3
규제화
일반화

다음 주 예고 · **CNN** — 이미지의 공간 구조를 유지하며 학습하는 신경망. 오늘 배운 ReLU · Adam · 드롭아웃이 그대로 쓰인다.