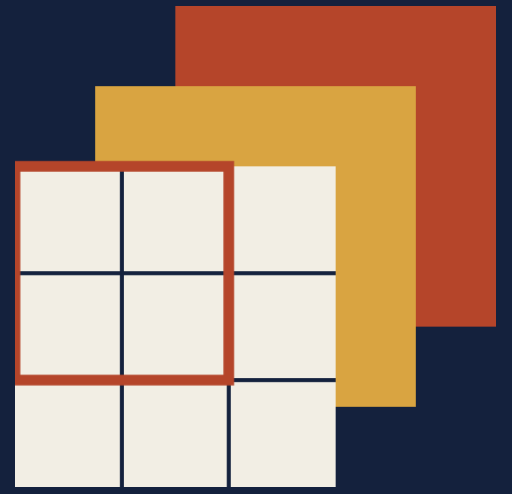
합성곱 신경망(CNN)

이미지의 공간 구조를 유지하는 신경망 · 합성곱과 풀링, 그리고 대표 CNN의 구조적 혁신



INTRO

오늘의 학습 목표와 진행 순서

01 이미지의 공간 구조를 유지하는 **합성곱 연산**의 계산 과정을 손으로 따라갈 수 있다.

02 **풀링 레이어**의 역할과 **이동 불변성**의 의미를 설명할 수 있다.

03 대표 CNN의 **구조적 혁신**을 분석하고, PyTorch로 **기본 분류기**를 구현할 수 있다.

진행 순서	시간
도입 · 지난 시간 복습	4분
Part 1 · 왜 CNN인가	8분
Part 2 · 합성곱 연산	13분
Part 3 · 풀링과 이동 불변성	8분
Part 4 · CNN 구조와 대표 모델	9분
Part 5 · 실습 안내	6분
정리 · 확인 문제	2분

INTRO

지난 시간 복습: MLP와 역전파

5주차

MLP 순전파

$h = \sigma(Wx + b)$

모든 입력이 모든 뉴런과 연결된 **완전연결층**을 행렬 곱으로 계산

6주차

역전파

$\partial L/\partial W =$ 연쇄 법칙

출력 쪽 오차를 거꾸로 전달하며 각 가중치의 기울기를 계산

7주차

기울기 소실

층↑ → 기울기 → 0

층이 깊어질수록 앞쪽 층의 학습이 멈춤. 오늘 **ResNet**에서 다시 만남

오늘의 질문 · 이 MLP에 사진 한 장을 그대로 넣으면 무슨 일이 생길까?

PART 1 · 왜 CNN인가

컴퓨터가 보는 이미지는 숫자의 격자다

12	15	20	190	210	225
10	18	24	195	215	228
14	16	22	188	212	230
11	17	21	192	208	226
13	19	23	198	216	229
12	14	20	191	211	224

6×6 흑백 이미지의 픽셀 값 (0 = 검정, 255 = 흰색)

흑백 이미지 · H × W

픽셀마다 밝기 하나. 실습에 쓸 Fashion-MNIST는 28 × 28

컬러 이미지 · H × W × 3

빨강·초록·파랑(RGB) 세 장의 격자를 겹친 3차원 텐서

Keras 표기 · (H, W, C)

채널(C)를 마지막에 쓴다. 배치를 붙이면 (B, C, H, W)

PART 1 · 왜 CNN인가

MLP로 이미지를 다루면 생기는 두 가지 문제

문제 ① 파라미터 폭발

약 1.5억

224 × 224 × 3 = 150,528개 입력을 은닉 뉴런 1,000개에 완전 연결하면 **첫 층에만** 가중치 약 1억 5천만 개가 필요하다.

→ 메모리·계산량 증가, 과적합 위험

문제 ② 공간 구조 손실

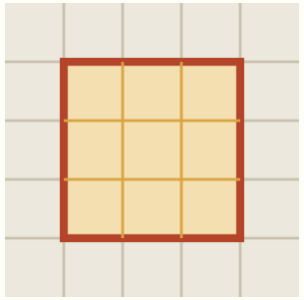
28×28 → 784×1

Flatten 하는 순간 **위·아래·옆 이웃**이라는 관계가 사라진다. 바로 아래 픽셀이 벡터에서는 28칸 떨어진 값이 된다.

같은 물체가 **몇 픽셀만 이동**해도 MLP에게는 전혀 다른 입력이 된다.

PART 1 · 왜 CNN인가

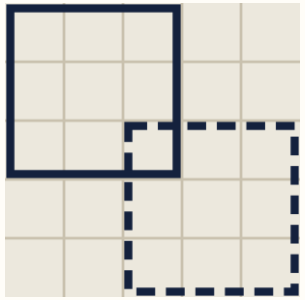
CNN의 두 가지 핵심 아이디어



지역 연결

Local connectivity

각 뉴런은 이미지 전체가 아니라 **작은 영역**(수용 영역)만 본다.



가중치 공유

Weight sharing

같은 필터를 모든 위치에 적용한다. 특징이 어디에 있든 같은 방식으로 찾는다.

결과: 파라미터 수는 이미지 크기와 무관하게 **필터 크기**로만 결정되고, 이웃 픽셀 관계가 그대로 유지된다. 생물학적 영감은 Hubel과 Wiesel(1959~)의 고양이 시각 피질 실험에서 밝혀진 **수용 영역** 개념이다.

PART 2 · 합성곱 연산

합성곱: 필터를 밀면서 곱하고 더한다

1 · 겹치기

입력의 한 영역 위에 F × F 크기의 **필터(커널)**를 겹친다.

2 · 곱하고 더하기

겹친 칸끼리 곱해 모두 더하고 편향 b를 더하면 **출력 한 칸**이 된다.

3 · 미끄러뜨리기

필터를 옮기며 반복하면 출력 격자, 곧 **특징 맵**이 완성된다.

$$y[i, j] = \Sigma_m \Sigma_n x[i+m, j+n] \cdot w[m, n] + b$$

참고 · 딥러닝 라이브러리의 '합성곱'은 수학적으로는 필터를 뒤집지 않는 **교차상관(cross-correlation)**이다. 필터 값은 어차피 학습되므로 결과에는 차이가 없다.

PART 2 · 합성곱 연산

손으로 계산하는 합성곱: 5×5 입력, 3×3 필터

입력 (5 × 5)

1	0	1	2	0
0	1	2	1	1
2	1	0	1	0
1	0	1	2	1
0	2	1	0	1

*

필터 (3 × 3)

1	0	−1
1	0	−1
1	0	−1

=

출력 특징 맵 (3 × 3)

0	−2	2
0	−2	1
1	0	0

첫 칸(노란 영역) 계산 · 행별로 곱해서 더하기

$$(1\cdot1 + 0\cdot0 + 1\cdot(-1)) + (0\cdot1 + 1\cdot0 + 2\cdot(-1)) + (2\cdot1 + 1\cdot0 + 0\cdot(-1)) = 0 - 2 + 2 = 0$$

PART 2 · 합성곱 연산

필터는 특징 탐지기다

1	0	−1
1	0	−1
1	0	−1

수직 엣지

왼쪽 − 오른쪽 밝기 차이

1	1	1
0	0	0
−1	−1	−1

수평 엣지

위 − 아래 밝기 차이

4번 슬라이드 이미지의 한 행 (세 행이 같다고 가정)

10	10	10	200	200	200

↓ 수직 엣지 필터 적용 결과

0	−570	−570	0

평평한 곳은 0, **경계가 걸친 곳에서만 크게 반응**한다. 부호는 밝기 변화의 방향(어두움 → 밝음)을 나타낸다.

핵심 · CNN은 필터 값을 사람이 정하지 않는다. 역전파로 데이터에 맞는 필터를 스스로 학습한다.

PART 2 · 합성곱 연산

출력 크기는 공식 하나로 계산한다

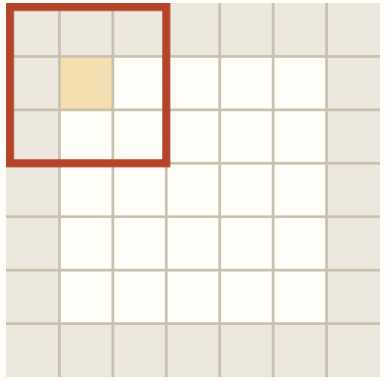
$$O = \lfloor (N + 2P - F) / S \rfloor + 1$$

N 입력 크기 · F 필터 크기 · P 패딩 · S 스트라이드 · ⌊ ⌋ 소수점 내림

N	F	P	S	출력 O	어디서 보나
5	3	0	1	3	앞의 손 계산 예제
5	3	1	1	5	입력 크기 유지('same' 패딩)
32	5	0	1	28	LeNet-5의 첫 합성곱 층
224	7	3	2	112	ResNet의 첫 층 (223/2 → 111, +1)

PART 2 · 합성곱 연산

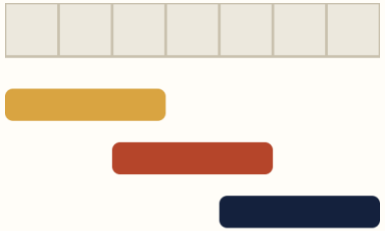
패딩과 스트라이드: 크기를 조절하는 두 손잡이



패딩 P

입력 테두리에 **0을 둘러** 출력 크기를 유지하고, 가장자리 픽셀도 필터 중심에 올 수 있게 한다.

`N=5, F=3, P=1 → O=5`



스트라이드 S

필터가 한 번에 **건너뛰는 칸 수**. S=2면 출력이 약 절반이 되어 다운샘플링 효과가 난다.

`N=7, F=3: S=1 → 5, S=2 → 3`

PART 2 · 합성곱 연산

컬러 이미지와 여러 개의 필터

입력

H × W × C_in

예: 224 × 224 × 3

→

필터 1개

F × F × C_in

깊이 = 입력 채널 수. 모든 채널을 합산해 맵 1장

→

필터 K개

맵 K장

필터마다 서로 다른 특징을 찾는다

→

출력

H′ × W′ × K

출력 채널 수 = 필터 개수

합성곱 층의 파라미터 수

$$(F \cdot F \cdot C_{in} + 1) \cdot K$$

+1은 필터마다 하나씩 있는 편향 b. 이미지 크기 H, W는 식에 **없다**.

1,792

3×3 필터 64개 합성곱 층
(3·3·3 + 1) · 64

약 1.5억

같은 입력의 MLP 첫 층
(은닉 뉴런 1,000개)

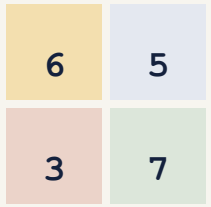
PART 3 · 풀링과 이동 불변성

풀링: 영역을 대표값 하나로 요약한다

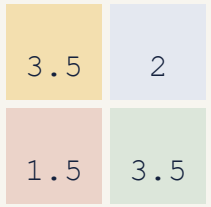
입력 특징 맵 (4 × 4)

1	3	2	1
4	**6**	**5**	0
3	1	1	2
0	2	**7**	4

2 × 2 창, 스트라이드 2



최대 풀링
가장 강한 반응만 남긴다 (주로 사용)



평균 풀링
영역의 평균을 남긴다

학습 파라미터 0개
최댓값·평균만 계산한다

크기를 절반으로
계산량은 줄고, 다음 층의 수용 영역은 넓어진다

작은 이동에 둔감
창 안에서 위치가 바뀌어도 결과가 같다 → 다음 장

이동 동변성과 이동 불변성

합성곱 → 동변성

입력이 이동하면 특징 맵도 **같이 이동**한다. 같은 필터를 모든 위치에 쓰기 때문.

풀링 → 불변성

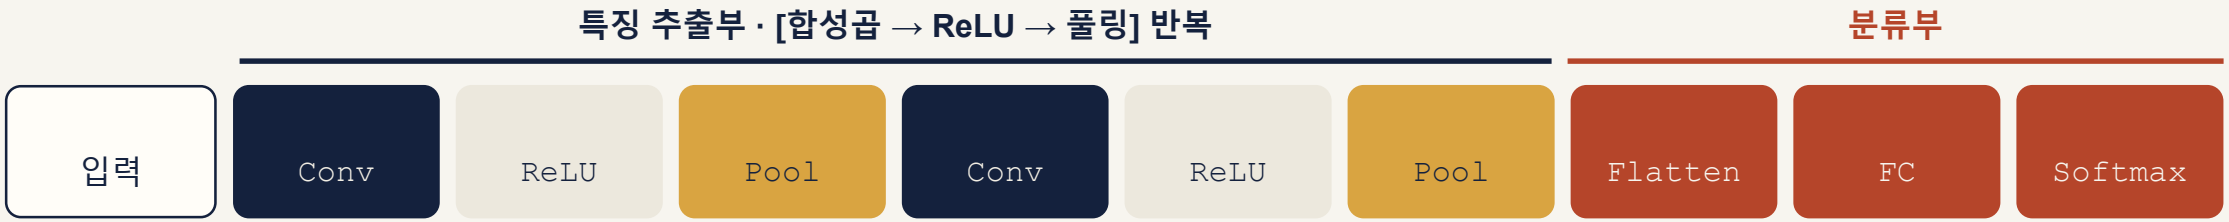
작은 이동에는 출력이 **변하지 않는다**. 창 안의 위치는 지워지고 '있다'만 남기 때문.

입력 (1차원 특징)	2칸 최대 풀링	기준 A와 비교
A [0, 9, 0, 0]	[9, 0]	기준
B [9, 0, 0, 0] ← 1칸	[9, 0]	같음 · 불변
C [0, 0, 9, 0] → 1칸	[0, 9]	달라짐 · 창 경계를 넘음

따라서 불변성은 **국소적·근사적**이다. 합성곱과 풀링을 여러 번 쌓을수록 허용되는 이동 범위가 넓어진다.

PART 4 · CNN 구조와 대표 모델

CNN의 전체 구조: 특징 추출부 + 분류부



앞쪽 층

엣지 · 색 대비

좁은 영역의 단순한 패턴

중간 층

질감 · 부분 모양

엣지를 조합한 무늬, 눈·바퀴 같은 부분

깊은 층

물체 수준 패턴

넓은 수용 영역으로 전체 형태를 포착

깊어질수록 공간 크기는 줄고 채널 수는 는다 · 실습 모델: 28×28×1 → 14×14×32 → 7×7×64

PART 4 · CNN 구조와 대표 모델

대표 CNN의 구조적 혁신

모델 (연도)	파라미터	핵심 혁신	의의
LeNet-5 (1998)	약 6만	합성곱 + 풀링 기본 골격	손글씨 숫자 인식
AlexNet (2012)	약 6,000만	ReLU · 드롭아웃 · GPU 학습	ILSVRC top-5 오류 15.3%
VGG-16 (2014)	약 1.38억	3×3 필터만 깊게 반복	단순하고 균일한 설계
GoogLeNet (2014)	약 700만	인셉션 모듈 · 1×1 합성곱	적은 파라미터로 깊게
ResNet (2015)	약 2,560만*	잔차 연결 (skip connection)	152층, top-5 오류 3.57%

흐름 · 더 깊게, 그러나 더 효율적으로. 깊이를 가능하게 한 열쇠는 작은 필터(VGG)와 지름길(ResNet)이다.

* ResNet-50 기준. 오류율은 ImageNet(ILSVRC) 분류 대회 결과이며 ResNet 수치는 앙상블 기준.

LeNet-5

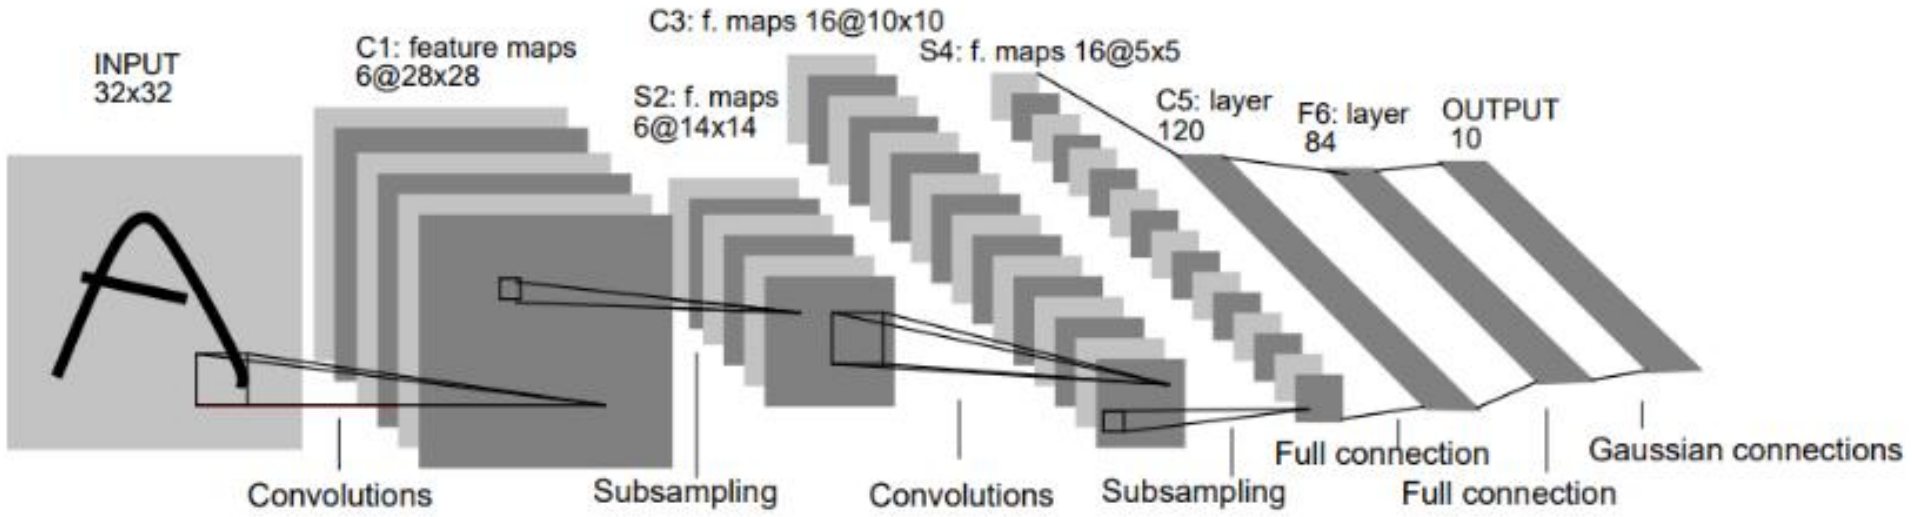
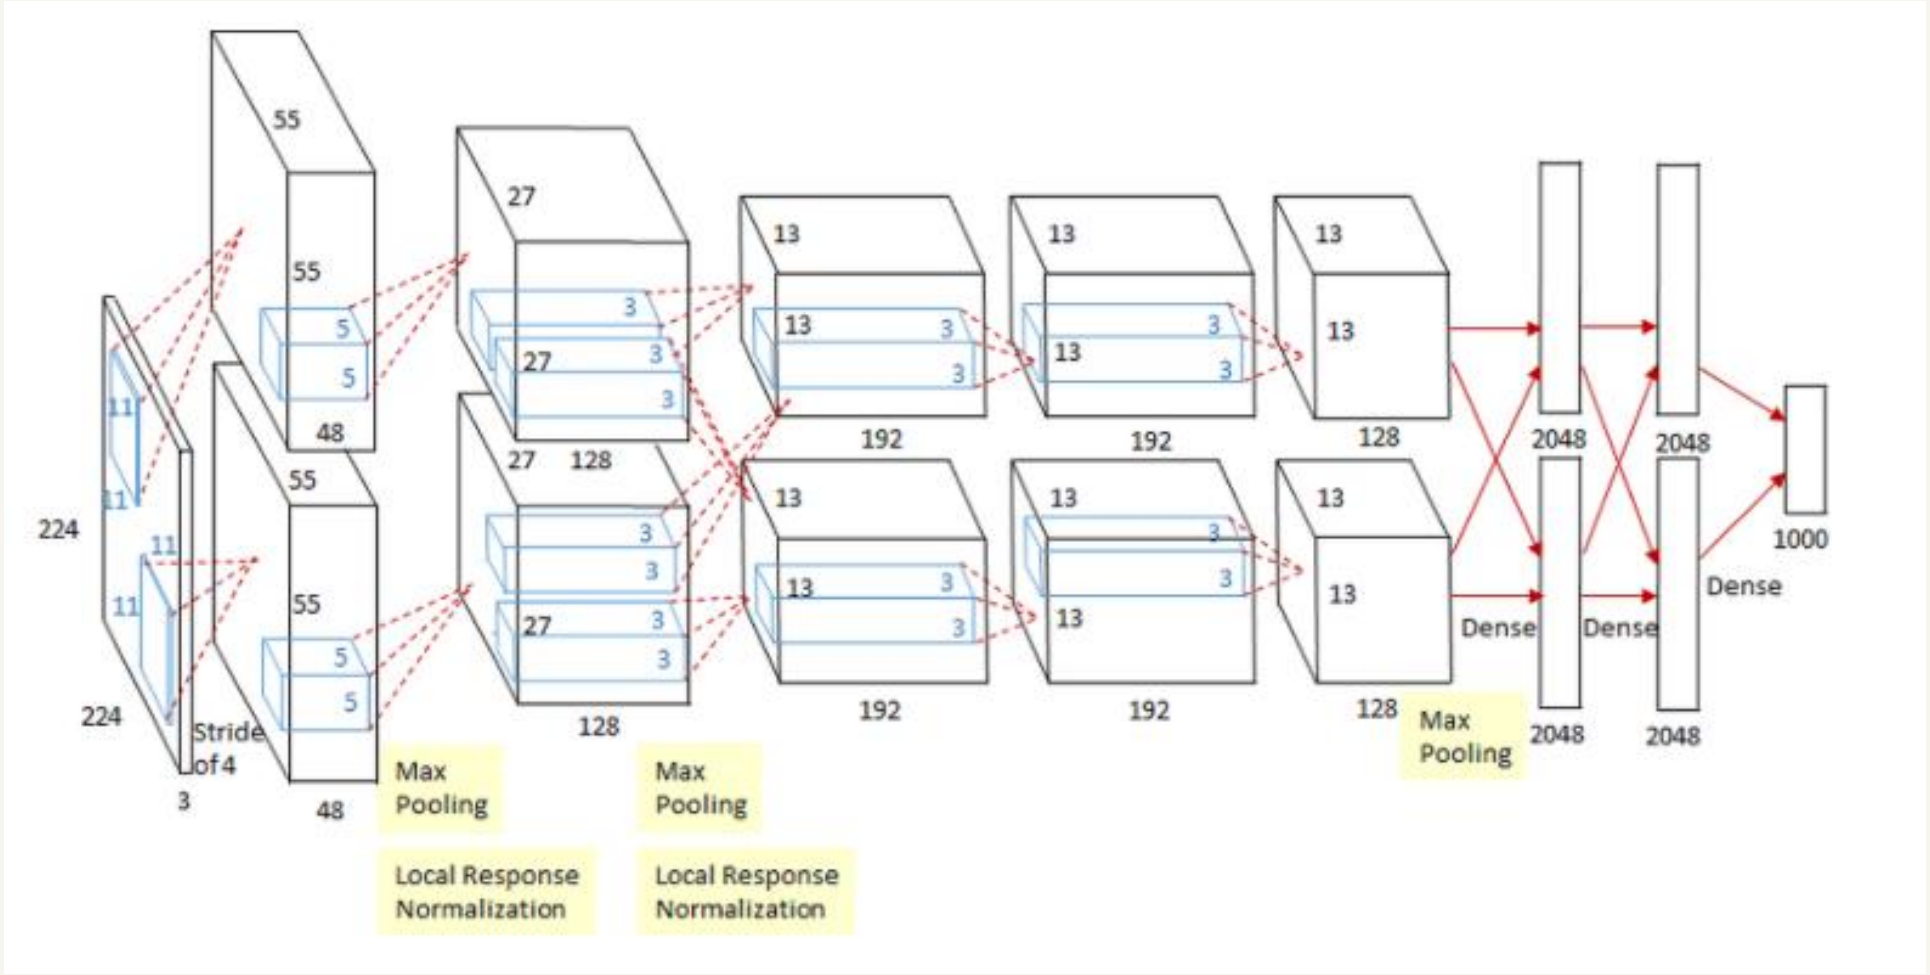
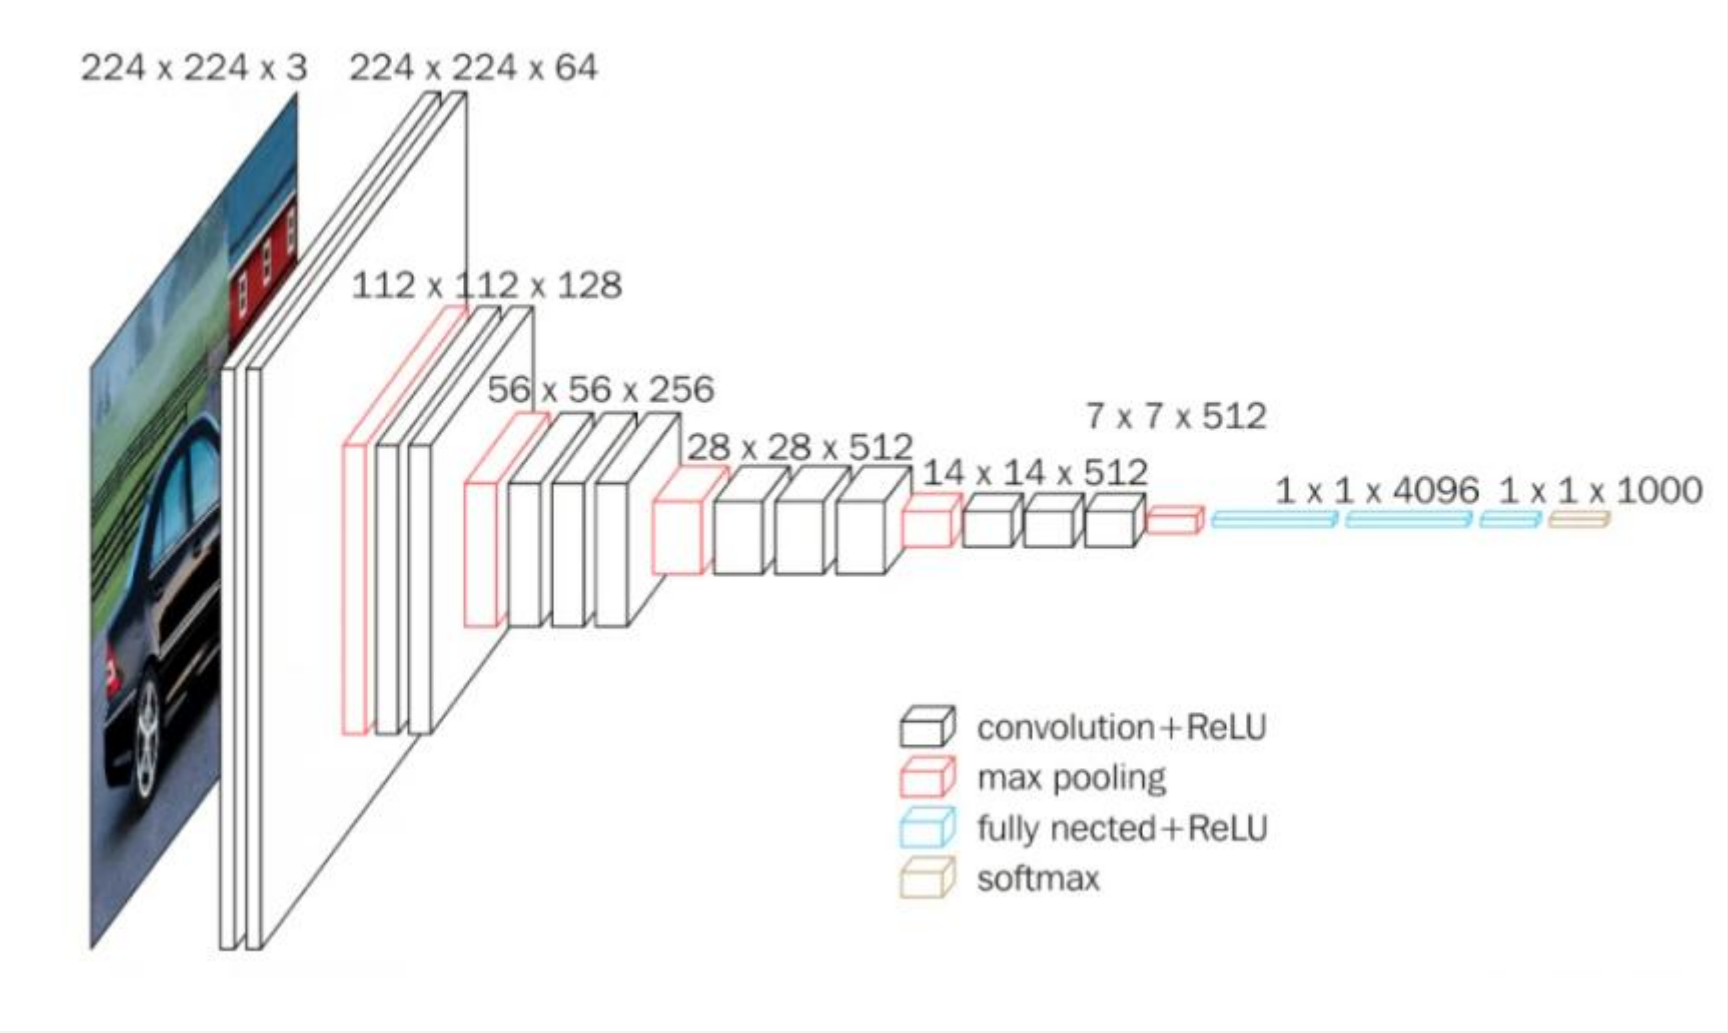


Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

AlexNet


55
55
48
55
55
48
27
27
128
27
128
13
13
192
13
13
192
13
13
128
13
13
192
13
13
192
13
13
128
2048
2048
2048
2048
1000
Dense
Dense
Dense
224
224
11
11
11
11
5
5
5
5
3
3
3
3
3
3
3
3
3
3
3
3
3
3
Stride
of 4
Max
Pooling
Max
Pooling
Max
Pooling
Local Response
Normalization
Local Response
Normalization

VGG-16

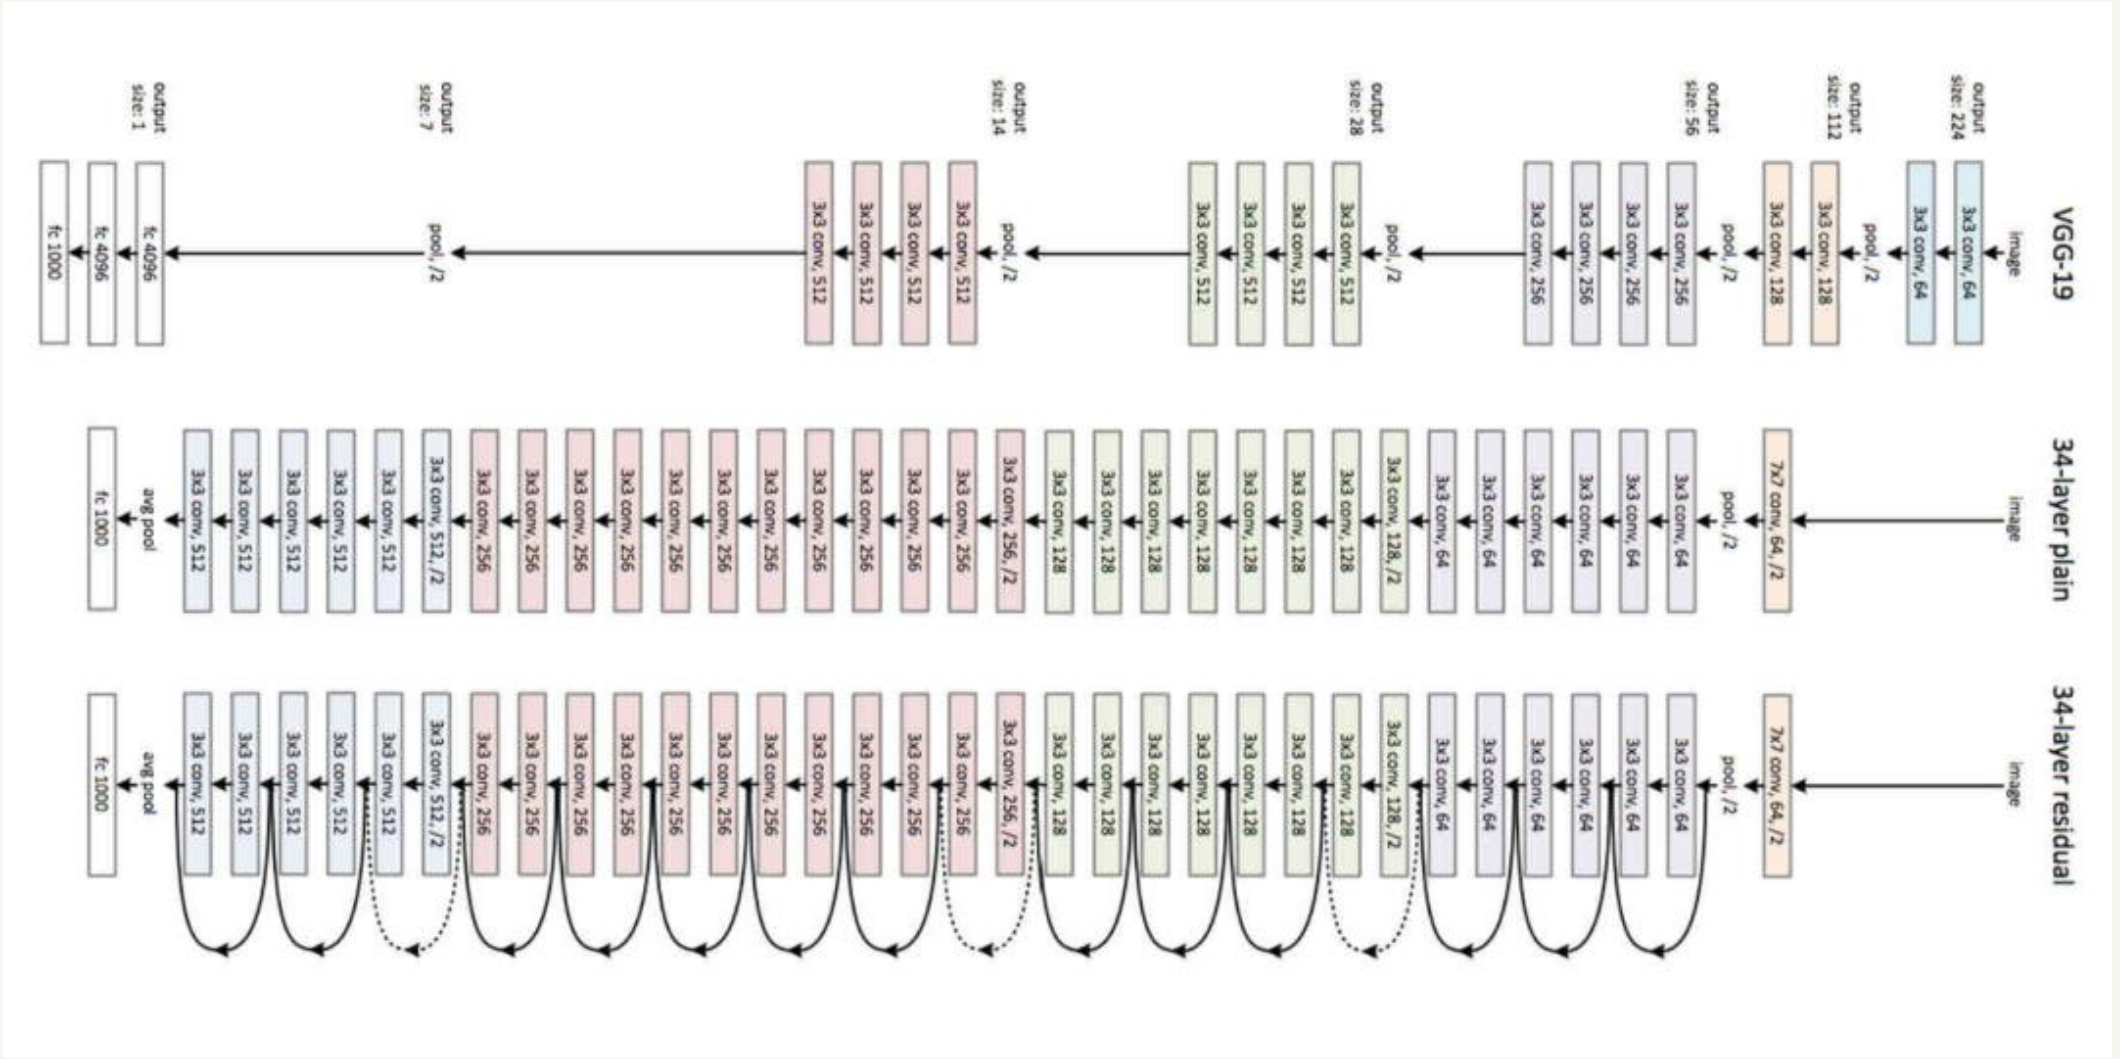

224 x 224 x 3
224 x 224 x 64
112 x 112 x 128
56 x 56 x 256
28 x 28 x 512
14 x 14 x 512
7 x 7 x 512
1 x 1 x 4096
1 x 1 x 1000
convolution+ReLU
max pooling
fully nected+ReLU
softmax

GoogleNet



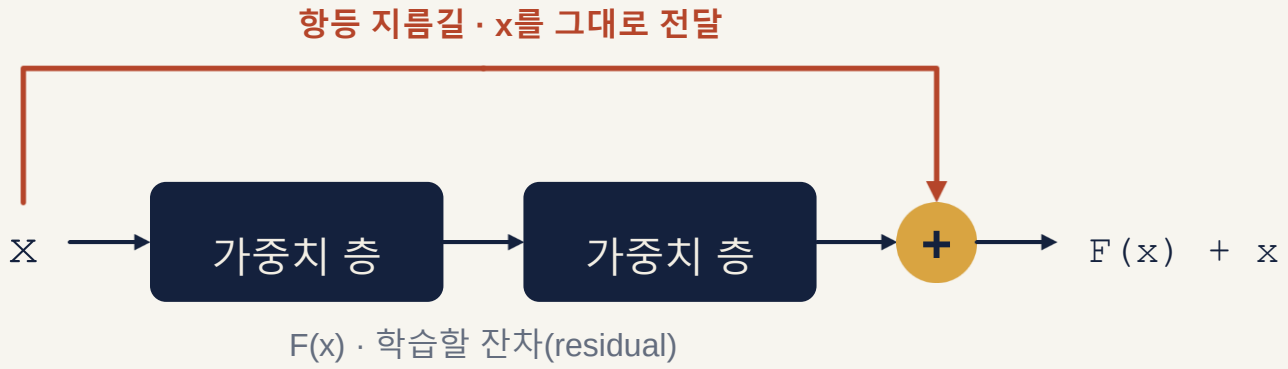
GoogLeNet의 구조도

ResNet


VGG-19
image
output size: 224
3x3 conv, 64
3x3 conv, 64
pool, /2
output size: 112
3x3 conv, 128
3x3 conv, 128
pool, /2
output size: 56
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
pool, /2
output size: 28
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 14
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
pool, /2
output size: 7
fc 4096
fc 4096
output size: 1
fc 1000
34-layer plain
image
7x7 conv, 64, /2
pool, /2
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 128, /2
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 256, /2
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 512, /2
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
avg pool
fc 1000
34-layer residual
image
7x7 conv, 64, /2
pool, /2
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 64
3x3 conv, 128, /2
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 128
3x3 conv, 256, /2
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 256
3x3 conv, 512, /2
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
3x3 conv, 512
avg pool
fc 1000

PART 4 · CNN 구조와 대표 모델

ResNet: 지름길로 기울기를 흘려보낸다



해결하려던 문제

일반 CNN을 깊게 쌓으면 **훈련 오차까지** 커졌다. CIFAR-10에서 56층이 20층보다 나빴다. 과적합이 아니라 **최적화**의 문제.

$$\partial y/\partial x = \partial F/\partial x + 1$$

역전파 때 항상 1이 더해지는 통로가 있어 기울기가 끊기지 않는다. 6주차의 **기울기 소실**에 대한 구조적 해답.

PART 5 · 실습 안내

실습: Keras로 만드는 첫 CNN 분류기

TensorFlow / Keras · Sequential 모델

```
from tensorflow import keras
from tensorflow.keras import layers

model = keras.Sequential([
    layers.Input(shape=(28, 28, 1)),
    layers.Conv2D(32, 3, padding="same", activation="relu"),
    layers.MaxPooling2D(2),      # 28 → 14
    layers.Conv2D(64, 3, padding="same", activation="relu"),
    layers.MaxPooling2D(2),      # 14 → 7
    layers.Flatten(),
    layers.Dense(128, activation="relu"),
    layers.Dense(10)             # logits
])
```

데이터

Fashion-MNIST · 28×28 흑백 의류 10종, 훈련 6만 장 / 테스트 1만 장

학습 설정

SparseCategoricalCrossentropy(from_logits=True), Adam(1e-3) 배치 64, 5 에폭

환경

Colab · 런타임 유형을 GPU로 변경. 전체 코드는 실습 노트북으로 배포

PART 5 · 실습 안내

텐서 모양과 파라미터 수 추적하기

층	출력 모양	파라미터 수
입력	(B, 1, 28, 28)	–
Conv2d 1→32, 3×3	(B, 32, 28, 28)	320
MaxPool2d(2)	(B, 32, 14, 14)	0
Conv2d 32→64, 3×3	(B, 64, 14, 14)	18,496
MaxPool2d(2)	(B, 64, 7, 7)	0
Flatten	(B, 3136)	0
Linear 3136→128	(B, 128)	401,536
Linear 128→10	(B, 10)	1,290
합계	ReLU는 파라미터 없음	421,642

95%

파라미터 대부분이 **완전연결층 하나**에 몰려 있다.

합성곱 층이 가벼운 이유는? 가중치 공유. 직접 확인해 보세요: (3·3·32 + 1)·64 = 18,496

WRAP-UP

오늘의 정리

01 지역 연결과 가중치 공유로 파라미터를 줄이고 공간 구조를 지킨다.

02 합성곱은 겹친 칸끼리 곱해 더하는 연산, 출력은 ⌊(N+2P−F)/S⌋+1.

03 필터는 학습되는 특징 탐지기, 파라미터는 (F·F·C_in+1)·K.

04 풀링은 크기를 줄이고 작은 이동에 대한 불변성을 준다.

05 VGG는 작은 필터로, ResNet은 지름길로 더 깊은 학습을 열었다.