인공지능기초 주차별 퀴즈 문제지

2~8주차 · 각 10문항 (총 70문항) · 정답과 풀이는 맨 뒤 <정답 및 풀이> 쪽에 있습니다

> **이 문제지에 대해**
> 원래 퀴즈의 문제 본문과 보기는 이전 대화에 남아 있지 않아서, **이전 대화에서 확인된 정답 내용과 주제**를 바탕으로 문제를 다시 만들었습니다. 따라서 표현과 보기(특히 오답 보기)는 원 퀴즈와 다를 수 있습니다.
> · 2·3·6·7·8주차: 원 퀴즈의 정답 내용을 그대로 살려 재구성 (6주차 3·5번은 원문을 알 수 없어 같은 유형의 유사 문제로 대체)
> · 4·5주차: 대화에 정답 기호만 남아 있어서, 주차별 정리 노트를 바탕으로 새로 만든 문제
> · 정답 기호(a~d)는 새로 섞은 것이므로 원 퀴즈의 기호와 무관합니다.

2주차 · 인공지능은 무엇을 학습하는가

1. 다음 중 분류(Classification) 문제에 해당하는 것은?

a. 다음 달 매출액 예측
b. 주택 가격 예측
c. 대출 부도 여부 판별
d. 내일 최고기온 예측

2. 머신러닝에서 '학습'에 대한 설명으로 가장 적절한 것은?

a. 프로그래머가 모든 규칙을 if-else로 직접 작성한다
b. 데이터를 그대로 저장해 두었다가 꺼내 보여준다
c. 모델은 고정하고 입력 데이터만 바꿔 본다
d. 입력 데이터와 정답의 관계를 알고리즘이 스스로 찾아낸다

3. y와 ŷ(y-hat)의 관계로 옳은 것은?

a. y는 모델의 예측값이고, ŷ은 실제 정답이다
b. y는 데이터셋에 기록된 실제 정답이고, ŷ은 모델 f가 X로부터 계산한 예측값이다
c. ŷ은 입력 특징 X를 가리킨다
d. y와 ŷ은 항상 같은 값이다

4. 스팸 메일 데이터셋에서 '관측 대상'과 '특징'을 바르게 구분한 것은?

a. 관측 대상과 특징은 같은 개념이다
b. 링크 개수는 정답 y이고, 스팸 여부는 특징이다
c. 하나의 이메일은 관측 대상이고, 문자 길이와 링크 개수 등은 특징이다
d. 문자 길이는 관측 대상이고, 하나의 이메일은 특징이다

5. 설비 고장 예측 프로젝트에서 문제를 가장 올바르게 구조화한 것은?

a. 고장이 난 뒤에 기록된 점검 결과까지 X에 모두 넣는다
b. 설비의 센서 정보 X를 정하고, 예측할 고장 y와 예측 시점을 명확히 정의한다
c. 일단 모델을 학습시킨 뒤 y를 나중에 정한다
d. 정답 y 없이 센서 값만 모아 둔다

6. 강화학습의 상호작용 구조를 바르게 나타낸 것은?

a. 데이터 → 군집 → 시각화
b. 특징 → 레이블 → 예측
c. 상태 → 행동 → 환경의 반응(보상)
d. 입력 → 정답 → 오차

7. 비지도학습의 특징으로 옳은 것은?

a. 모든 데이터에 반드시 정답 y가 있어야 한다
b. 항상 연속 수치를 예측한다
c. 행동의 결과로 받는 보상을 최대화한다
d. 정답(y) 없이 오직 입력 특징(X)만으로 데이터에 숨겨진 구조를 찾는다

8. 설비 고장 예측에서 데이터 누출 없이 올바르게 설계한 것은?

a. 고장 여부 y 자체를 입력 X에 포함한다
b. 현재까지 수집된 설비의 진동, 온도, 압력으로 향후 24시간 내 고장 여부를 예측한다
c. 향후 24시간 동안의 센서 값까지 입력에 포함한다
d. 고장 이후에 작성된 수리 보고서의 내용을 입력 X로 사용한다

9. $\hat{y} = f(X)$에서 각 기호의 의미로 옳은 것은?

a. X는 예측값, f는 정답, $\hat{y}$은 입력 특징이다
b. X는 정답, f는 오차, $\hat{y}$은 입력 특징이다
c. X는 입력 특징, f는 학습된 모델, $\hat{y}$은 모델의 예측값이다
d. X는 하이퍼파라미터, f는 데이터, $\hat{y}$은 정답이다

10. AI 모델 개발의 윤리 측면에서, 개발자가 던져야 할 적절한 질문은?

a. 정확도가 높으니 어떤 데이터를 써도 문제없는가?
b. 개인정보는 성능과 무관하므로 신경 쓰지 않아도 되는가?
c. 편향 점검은 배포 이후 사용자가 알아서 하면 되는가?
d. 모델의 정확도만 높아지면 개인정보나 편향 문제는 고려하지 않아도 되는가?

3주차 · 인공지능의 진짜 실력을 묻다

1. 학습 과정에서 조정되는 선형 모델 $\hat{y} = wx + b$의 파라미터는?

a. 훈련 데이터와 테스트 데이터
b. w와 b
c. x와 y
d. 학습률과 에폭 수

2. MSE에서 오차를 제곱하는 이유로 알맞은 것은?

a. 오차가 음수가 되지 않게 하되 큰 오차를 오히려 덜 반영하기 위해서다
b. 계산 속도를 높이기 위해서다
c. 오차를 항상 0으로 만들기 위해서다
d. +오차와 −오차가 상쇄되는 것을 막고, 큰 오차에 더 무거운 벌점을 주기 위해서다

3. 경사하강법에서 학습률이 너무 클 때 나타날 수 있는 현상은?

a. 손실이 항상 정확히 0이 된다
b. 파라미터가 전혀 갱신되지 않는다
c. 최솟값 주변을 크게 오가면서 학습이 불안정해질 수 있다
d. 항상 더 빠르고 안정적으로 수렴한다

4. 검증(Validation) 데이터의 역할로 알맞은 것은?

a. 모델의 최종 성능을 단 한 번 보고하는 데 사용한다
b. 훈련 데이터를 대체하는 데 사용한다
c. 하이퍼파라미터 선택과 모델 설정을 조정하는 데 사용한다
d. 모델의 가중치를 직접 학습시키는 데 사용한다

5. 테스트 데이터를 보면서 모델을 반복적으로 수정하면 생기는 문제는?

a. 모델의 파라미터 수가 자동으로 줄어든다
b. 아무 문제 없고 오히려 일반화 성능이 더 정확해진다
c. 훈련 손실이 반드시 증가한다
d. 테스트 데이터가 사실상 간접적으로 학습에 사용되어, 그 성능이 일반화 성능을 더 이상 보장하지 못한다

6. MSE의 제곱근으로, 원래 데이터와 같은 단위로 해석할 수 있는 회귀 지표는?

a. RMSE
b. 정확도(Accuracy)
c. 재현율(Recall)
d. 정밀도(Precision)

7. 정상:환자 = 99:1인 데이터에서 정확도만으로 평가하면 위험한 이유는?

a. 데이터 불균형 상황에서 소수 클래스의 예측 실패를 전혀 잡아내지 못한다
b. 정확도는 회귀 문제에만 쓰는 지표이다
c. 정확도는 분류 문제에서 계산할 수 없다
d. 정확도는 항상 1에 가까울 수 없다

8. 모델 A는 정답 클래스에 확률 0.1을, 모델 B는 0.9를 부여했다. 교차엔트로피 손실을 비교한 것으로 옳은 것은?

a. 손실은 확률과 무관하고 정답 여부만으로 정해진다
b. A의 손실이 B보다 훨씬 크다. 정답에 낮은 확률을 부여할수록 벌점이 커지기 때문이다
c. B의 손실이 A보다 훨씬 크다
d. 두 모델의 손실은 같다

9. '실제 양성 중에서 모델이 양성으로 맞힌 비율'에 해당하는 지표는?

a. RMSE
b. 재현율(Recall)
c. 정확도(Accuracy)
d. 정밀도(Precision)

10. 거짓 양성(False Positive)의 설명으로 옳은 것은?

a. 실제 정답이 음성이고 음성으로 맞게 예측한 경우
b. 실제 정답은 양성인데 음성이라고 예측한 경우
c. 실제 정답이 양성이고 양성으로 맞게 예측한 경우
d. 실제 정답은 음성인데 양성이라고 틀리게 예측한 경우

4주차 · 정답 없이 데이터 스스로 말하게 하는 법

1. 다음 중 정답 y 없이는 수행하기 어려운 작업은?

a. 스팸 메일인지 아닌지 분류하는 모델 학습
b. 내용이 비슷한 문서끼리 군집화
c. 구매 패턴이 비슷한 고객군 묶기
d. 정상 패턴에서 멀리 떨어진 사례 찾기(이상 탐지)

2. K-means가 군집을 완성해 가는 순서로 알맞은 것은?

a. 갱신 → 종료 → 배정 → 확인
b. 배정(가까운 중심으로) → 갱신(중심 재계산) → 확인(아직 움직이는가) → 종료
c. 정답 확인 → 가중치 갱신 → 배정 → 종료
d. 종료 → 배정 → 갱신 → 확인

3. K-means에서 군집 수 K를 키울수록 군집 내 거리 손실(inertia)은 어떻게 되며, 이때 주의점은?

a. inertia가 가장 작은 K가 항상 현실의 정답이다
b. K가 커질수록 inertia는 증가하므로 K는 작을수록 좋다
c. K와 inertia는 무관하다
d. K가 커질수록 inertia는 감소하므로, inertia가 가장 작다는 이유만으로 K를 고르면 안 된다

4. Iris 데이터에 K-means(K=3)를 적용한 결과의 군집 번호 0, 1, 2에 대한 설명으로 옳은 것은?

a. 실제 정답 y를 학습해 얻은 라벨이다
b. 품종 이름이 아니라 단순한 군집 ID이다
c. 번호가 클수록 꽃잎이 크다는 뜻이다
d. 각각 setosa, versicolor, virginica와 순서대로 일치한다

5. K-means 전에 표준화(StandardScaler)를 하는 이유는?

a. 표준화를 하면 K를 자동으로 정해 주기 때문이다
b. K-means는 거리를 쓰기 때문에 특징의 단위와 크기에 결과가 좌우되기 때문이다
c. K-means는 정답 y를 사용하기 때문이다
d. 표준화를 하면 군집 수가 반드시 줄어들기 때문이다

6. 차원의 저주에 대한 설명으로 옳은 것은?

a. 차원이 늘수록 항상 모델 성능이 좋아진다
b. 차원이 늘어날수록 이웃이 더 많이 생겨 거리 계산이 쉬워진다
c. 차원이 늘어나면 필요한 데이터 양은 변하지 않는다
d. 차원이 늘어나면 공간이 방대해져 데이터가 고립되고, 최근접·최원 거리의 차이가 희미해진다

7. PCA의 제1주성분(PC1)은 무엇인가?

a. 데이터의 분산이 가장 크게 퍼지는 방향으로, 가장 큰 고유값에 대응하는 고유벡터이다
b. 분산이 가장 작은 방향이다
c. 원래 특징 중 하나를 그대로 고른 것이다
d. 정답 y와 상관이 가장 큰 특징이다

8. PCA를 적용하는 단계를 순서대로 바르게 나열한 것은?

a. 중심화·표준화 → 공분산 계산 → 축 선택(고유값 큰 순) → 투영
b. 투영 → 공분산 계산 → 축 선택 → 표준화
c. 축 선택 → 투영 → 표준화 → 공분산 계산
d. 공분산 계산 → 투영 → 표준화 → 축 선택

9. 데이터 누출을 막는 올바른 방법은?

a. 테스트 데이터로 fit한 기준을 훈련 데이터에 적용한다
b. 훈련과 테스트 데이터를 합친 뒤 한꺼번에 fit한다
c. 누출은 K-means에서는 발생하지 않으므로 신경 쓰지 않는다
d. 훈련 데이터로만 기준(fit)을 잡고, 테스트 데이터에는 변환(transform)만 적용한다

10. Iris에서 K-means 결과를 실제 품종과 비교하는 이유와 결론으로 알맞은 것은?

a. 군집 결과는 항상 실제 품종과 완전히 일치한다
b. 군집은 정답 없이 만든 그룹이므로 실제 품종과 일치한다는 보장이 없고, 비교를 통해 비슷한 부분과 다른 부분을 확인한다
c. 군집과 분류는 같은 문제이므로 비교할 필요가 없다
d. 비교 결과가 다르면 K-means 구현이 잘못된 것이다

5주차 · 퍼셉트론에서 다층 퍼셉트론까지

1. 퍼셉트론에서 가중치(w)의 역할은?

a. 입력 데이터를 저장하는 것
b. 가중합 결과를 0 또는 1로 바꾸는 것
c. 예측값과 정답의 차이를 계산하는 것
d. 각 입력 정보의 중요도(영향력)를 결정하는 '볼륨 조절기'

2. x_1=0.8, x_2=0.5, w_1=0.6, w_2=0.4, b=−0.5이고 활성화는 'z ≥ 0이면 1, 아니면 0'일 때 출력 y는?

a. z = 0.18 이므로 y = 1
b. z = −0.18 이므로 y = 1
c. z = 0.18 이므로 y = 0
d. z = 1.18 이므로 y = 0

3. 퍼셉트론의 편향(b)에 대한 설명으로 옳은 것은?

a. 층의 개수를 결정한다
b. 각 입력의 중요도를 결정한다
c. 판단 기준(결정 경계)의 위치를 이동시킨다
d. 학습률을 조절한다

4. 단층 퍼셉트론이 XOR 문제를 풀 수 없는 이유는?

a. 학습 횟수가 부족하기 때문이다
b. 활성화 함수로 ReLU를 쓰기 때문이다
c. 하나의 직선(선형 결정 경계)으로는 XOR을 분리할 수 없기 때문이다
d. 입력이 2개뿐이기 때문이다

5. 활성화 함수 없이 선형 층만 100층 쌓으면 어떻게 되는가?

a. 층이 깊어진 만큼 표현력이 100배가 된다
b. 자동으로 비선형 변환이 추가된다
c. 수학적으로 하나의 선형식으로 압축되어 표현력이 늘지 않는다
d. 기울기 소실이 반드시 해결된다

6. ReLU에 대한 설명 중 옳지 않은 것은?

a. y = max(0, z)로 표현된다
b. 현대 신경망의 은닉층에서 널리 쓰인다
c. 양수 입력은 0으로 막고, 음수 입력은 그대로 통과시킨다
d. 음수 입력은 0으로 차단한다

7. z = [−2, 0, 4]에 ReLU를 적용한 결과는?

a. [0, 0, 4]
b. [0, 0, 0]
c. [−2, 0, 4]
d. [2, 0, 4]

8. 계단 함수(Step)가 현대 신경망에서 퇴출된 가장 큰 이유는?

a. 출력이 항상 음수이기 때문이다
b. 연산이 너무 느리기 때문이다
c. 입력이 2개를 넘으면 계산할 수 없기 때문이다
d. 너무 극단적이며 미분이 불가능해 신경망을 학습시킬 수 없기 때문이다

9. **X가 (4×2), W_1이 (2×3)일 때 XW_1의 shape은?**

a. (4×3)
b. (2×3)
c. (4×2)
d. 곱셈이 불가능하다

10. **은닉 뉴런 수를 늘리면 모든 분류 문제에서 항상 더 좋은 성능이 나오는가?**

a. 아니다. 복잡한 결정 경계가 항상 좋은 것은 아니며 과적합이 생길 수 있다
b. 그렇다. 뉴런이 많을수록 학습 오차는 늘고 일반화 성능이 좋아진다
c. 아니다. 은닉 뉴런 수는 성능과 무관하다
d. 그렇다. 뉴런이 많을수록 항상 성능이 좋아진다

6주차 · 다층 퍼셉트론은 가중치를 어떻게 스스로 고칠까

1. 신경망 학습에서 수정되는 대상은?

a. 가중치
b. 정답 y
c. 입력 데이터 X
d. 데이터셋의 크기

2. 신경망 학습의 한 스텝 순서로 알맞은 것은?

a. 가중치 수정 → 예측 → 기울기 계산 → 손실 계산
b. 손실 계산 → 예측 → 가중치 수정 → 기울기 계산
c. 예측 → 손실 계산 → 기울기 계산 → 가중치 수정
d. 예측 → 기울기 계산 → 손실 계산 → 가중치 수정

3. 현재 w = 3.0, dL/dw = 5, 학습률 0.1일 때 경사하강법으로 갱신된 w는? ***(원 퀴즈와 같은 유형의 유사 문제)***

a. 2.9
b. 0.5
c. 2.5
d. 3.5

4. 교차엔트로피 손실에서 정답 범주에 대한 확신이 낮아지면?

a. 손실은 변하지 않는다
b. 손실이 0이 된다
c. 손실이 증가한다
d. 손실이 감소한다

5. 정답 y = 1, 예측 $\hat{y}$ = 0.4일 때 오차 (y − $\hat{y}$)는? ***(유사 문제)***

a. 0.6
b. 1.4
c. −0.6
d. 0.4

6. 순전파(Forward Propagation)의 방향과 목적은?

a. 정답에서 입력을 역으로 계산한다
b. 오른쪽에서 왼쪽으로 손실의 기울기를 계산한다
c. 가중치를 무작위로 초기화한다
d. 왼쪽(입력)에서 오른쪽(출력)으로 값을 계산하여 예측값을 도출한다

7. 역전파(Backpropagation)의 방향과 목적은?

a. 오른쪽(출력 측)에서 왼쪽(입력 측)으로 손실의 기울기를 계산한다
b. 왼쪽에서 오른쪽으로 예측값을 도출한다
c. 입력 데이터를 정규화한다
d. 손실을 계산하지 않고 가중치만 갱신한다

8. $dL/d\hat{y}$ = 0.5, $d\hat{y}/dz$ = 4, dz/dw = 0.01일 때 dL/dw는? ***(원 퀴즈와 같은 유형)***

a. 0.005
b. 0.02
c. 2.0
d. 0.2

9. $u = 2x$, $L = u^2$일 때 $x = 3$에서 dL/dx는?

a. 24
b. 12
c. 36
d. 6

10. 가중치 w에 대한 손실의 기울기를 연쇄법칙으로 나타낸 식은? ($z = wx+b$, $h = f(z)$, $\hat{y} = g(h)$)

a. $dL/dw = (dL/d\hat{y})(d\hat{y}/dh)(dh/dz)(dz/dw)$
b. $dL/dw = (dz/dw)(dw/dL)$
c. $dL/dw = (dL/d\hat{y}) + (d\hat{y}/dh) + (dh/dz) + (dz/dw)$
d. $dL/dw = dL/d\hat{y} - dz/dw$

7주차 · 깊은 신경망, 어떻게 잘 배우게 할까

1. ReLU를 쓰는 은닉층에 적합한 가중치 초기화와 분산은?

a. 모든 가중치를 1로 초기화
b. 모든 가중치를 0으로 초기화
c. Xavier 초기화, Var(w) = 2/(n_in + n_out)
d. He 초기화, Var(w) = 2/n_in

2. 시그모이드를 깊은 층에 쌓으면 기울기 소실이 생기는 직접적 이유는?

a. 도함수가 항상 음수이다
b. 출력이 0~1을 벗어난다
c. 미분이 불가능하다
d. 도함수의 최댓값이 0.25에 불과하다

3. 모멘텀 v_t = 0.9·v_{t−1} + g_t, g_t = 1(항상), v_0 = 0일 때 v_3는?

a. 2.9
b. 2.71
c. 3.0
d. 1.9

4. 가중치 절댓값의 합에 벌점을 부여해 과적합을 줄이는 방법은?

a. 드롭아웃
b. 조기 종료
c. L2 규제
d. L1 규제

5. ReLU에서 입력이 계속 음수라 기울기가 0이 되는 문제(죽은 ReLU)의 대표적 해결책은?

a. 활성화 함수를 계단 함수로 바꾼다
b. 학습률을 0으로 만든다
c. 가중치를 모두 0으로 초기화한다
d. Leaky ReLU로 음수 구간에 작은 기울기를 둔다

6. 드롭아웃(Dropout)의 동작으로 옳은 것은?

a. 테스트 때만 무작위로 뉴런을 끈다
b. 훈련 때는 모든 뉴런을 켜고 테스트 때 무작위로 끈다
c. 훈련·테스트 모두 같은 뉴런만 끈다
d. 훈련 중에는 매 단계 무작위로 일부 뉴런의 출력을 0으로 하고, 테스트 때는 모든 뉴런을 켠다

7. Adagrad와 RMSprop의 차이로 옳은 것은?

a. 둘 다 모멘텀을 사용한다
b. Adagrad는 지수이동평균을 쓰고, RMSprop은 제곱 기울기를 계속 누적한다
c. 둘 다 학습률을 사용하지 않는다
d. Adagrad는 보폭이 영구적으로 줄어들 수 있으나, RMSprop은 지수이동평균을 쓴다

8. 검증 손실이 에폭 1~6에서 0.60, 0.52, 0.45, 0.39, 0.41, 0.40이다. patience = 2인 조기 종료에서 중단 시점과 복원할 가중치는?

a. 에폭 6에서 중단, 에폭 4의 가중치 사용
b. 에폭 4에서 중단, 에폭 4의 가중치 사용
c. 에폭 5에서 중단, 에폭 4의 가중치 사용
d. 에폭 6에서 중단, 에폭 6의 가중치 사용

9. **w = 2.0, 기울기 dL/dw = −3.0, 학습률 0.1일 때 갱신된 w는?**

a. 2.3
b. 1.7
c. −1.0
d. 2.1

10. **Adam 옵티마이저를 가장 잘 설명한 것은?**

a. Adagrad의 영구 축소 보폭과 L1 규제를 결합했다
b. 드롭아웃과 조기 종료를 결합했다
c. 모멘텀의 방향 기억과 RMSprop의 보폭 조정을 결합했다
d. He 초기화와 Xavier 초기화를 결합했다

8주차 · 합성곱 신경망

1. 입력 28×28×1 → Conv(3×3, 32개, same) → MaxPool(2×2) → Conv(3×3, 64개, same) → MaxPool(2×2) → Flatten. Flatten 후 벡터의 길이는?

a. 3,136
b. 12,544
c. 6,272
d. 1,568

2. CNN에 대한 설명 중 옳지 않은 것은?

a. 패딩을 사용하면 출력 크기를 조절할 수 있다
b. 최대 풀링(Max Pooling)을 수행할 때 학습해야 할 파라미터가 존재한다
c. 합성곱 층은 같은 필터를 입력 전체에 공유하여 적용한다
d. 풀링은 특징 맵의 크기를 줄인다

3. 입력 채널이 16개인 특징 맵에 3×3 필터 32개를 적용하는 합성곱 층의 파라미터 수(편향 포함)는?

a. 320
b. 9,248
c. 4,640
d. 4,608

4. 5×5 입력에 3×3 필터, 스트라이드 1, 패딩 0을 적용한 출력의 크기는?

a. 2×2
b. 3×3
c. 4×4
d. 5×5

5. CNN 구조와 핵심 아이디어의 연결이 올바른 것은?

a. GoogLeNet : 잔차 연결(Skip Connection)
b. VGG-16 : 인셉션 모듈
c. ResNet : 인셉션 모듈
d. ResNet : 잔차 연결(Skip Connection)

6. CNN의 계층적 특징 학습에 대한 설명으로 옳은 것은?

a. 깊은 층은 색 정보만 포착한다
b. 앞쪽 층에서는 엣지나 색 대비 같은 단순한 패턴을, 깊은 층에서는 물체 수준의 전체 형태를 포착한다
c. 모든 층이 동일한 수준의 패턴을 포착한다
d. 앞쪽 층에서 물체 전체 형태를, 깊은 층에서 엣지를 포착한다

7. 합성곱 층에서 패딩(Padding)의 목적은?

a. 파라미터 수를 0으로 만든다
b. 입력의 가장자리를 확장하여 출력 크기를 조절한다
c. 클래스 수를 늘린다
d. 학습률을 자동으로 조절한다

8. VGG-16의 특징으로 알맞은 것은?

a. 작고 균일한 3×3 필터만을 깊게 반복해서 쌓아 올렸다
b. 인셉션 모듈로 여러 크기의 필터를 병렬로 사용했다
c. 풀링 없이 완전연결층만 사용했다
d. 잔차 연결로 입력을 출력에 더했다

9. 이미지를 MLP에 입력할 때의 문제점이 아닌 것은?

a. 입력 픽셀 수가 커질수록 파라미터 수가 급격히 늘어난다
b. 공간 구조가 유지되어 픽셀 간의 이웃 관계가 보존된다
c. 이웃 픽셀 사이의 관계를 활용하기 어렵다
d. 이미지를 1차원으로 펼치면서 공간 구조가 사라진다

10. 합성곱 층의 파라미터 수에 대한 설명으로 옳은 것은?

a. 입력 이미지가 커지면 파라미터 수도 같은 비율로 늘어난다
b. 합성곱 층의 파라미터 수는 입력 이미지의 가로, 세로 크기와 무관하다
c. 파라미터 수는 풀링 크기로 정해진다
d. 파라미터 수는 필터 개수와 무관하다

정답 및 풀이

2주차 · 인공지능은 무엇을 학습하는가

#	정답	풀이
1	**c. 대출 부도 여부 판별**	예/아니오를 맞히므로 분류. 나머지는 연속 수치를 예측하는 회귀.
2	**d. 입력 데이터와 정답의 관계를 알고리즘이 스스로 찾아낸다**	학습은 입력과 정답의 관계를 이용해 모델 내부 매개변수를 조정하는 과정.
3	**b. y는 데이터셋에 기록된 실제 정답이고, ŷ은 모델 f가 X로부터 계산한 예측값이다**	y = 실제 정답, ŷ = f(X) = 예측값. 둘의 차이가 오차.
4	**c. 하나의 이메일은 관측 대상이고, 문자 길이와 링크 개수 등은 특징이다**	행 = 관측(샘플), 열 = 특징(feature).
5	**b. 설비의 센서 정보 X를 정하고, 예측할 고장 y와 예측 시점을 명확히 정의한다**	AI 프로젝트는 X, y, 예측 시점을 정의하는 문제 구조화에서 시작.
6	**c. 상태 → 행동 → 환경의 반응(보상)**	정답표 대신 행동의 결과로 받는 누적 보상을 최대화하도록 학습.
7	**d. 정답(y) 없이 오직 입력 특징(X)만으로 데이터에 숨겨진 구조를 찾는다**	군집화, 차원 축소 등이 대표적.
8	**b. 현재까지 수집된 설비의 진동, 온도, 압력으로 향후 24시간 내 고장 여부를 예측한다**	예측 시점에 알 수 없는 정보를 쓰면 성능 착시가 생긴다.
9	**c. X는 입력 특징, f는 학습된 모델, ŷ은 모델의 예측값이다**	X → f → ŷ.
10	**d. 모델의 정확도만 높아지면 개인정보나 편향 문제는 고려하지 않아도 되는가?**	이 질문의 답은 '아니오'. 정확도가 높아도 개인정보·편향은 별도로 점검해야 한다. (원 퀴즈의 정답 문장을 그대로 사용)

3주차 · 인공지능의 진짜 실력을 묻다

#	정답	풀이
1	**b. w와 b**	학습률·에폭은 하이퍼파라미터, w와 b가 파라미터.
2	**d. +오차와 −오차가 상쇄되는 것을 막고, 큰 오차에 더 무거운 벌점을 주기 위해서다**	(+2)와 (−2)가 서로 상쇄되는 것을 막고 큰 오차를 더 크게 벌한다.
3	**c. 최솟값 주변을 크게 오가면서 학습이 불안정해질 수 있다**	너무 크면 진동·발산, 너무 작으면 학습이 매우 느림.
4	**c. 하이퍼파라미터 선택과 모델 설정을 조정하는 데 사용한다**	훈련=파라미터 학습, 검증=설정 조정, 테스트=최종 평가.
5	**d. 테스트 데이터가 사실상 간접적으로 학습에 사용되어, 그 성능이 일반화 성능을 더 이상 보장하지 못한다**	테스트 데이터는 최종 평가에 한 번만 사용해야 한다.
6	**a. RMSE**	RMSE = $\sqrt{}$MSE.
7	**a. 데이터 불균형 상황에서 소수 클래스의 예측 실패를 전혀 잡아내지 못한다**	항상 '정상'이라고 찍어도 정확도 99%가 나온다.
8	**b. A의 손실이 B보다 훨씬 크다. 정답에 낮은 확률을 부여할수록 벌점이 커지기 때문이다**	정답이 1인데 0.1로 예측하면 큰 손실.
9	**b. 재현율(Recall)**	Recall = TP / (TP + FN).

10	**d. 실제 정답은 음성인데 양성이라고 틀리게 예측한 경우**	실제 양성인데 음성으로 예측하면 FN(거짓 음성). 양성·양성은 TP, 음성·음성은 TN.

4주차 · 정답 없이 데이터 스스로 말하게 하는 법

#	정답	풀이
1	**a. 스팸 메일인지 아닌지 분류하는 모델 학습**	스팸 분류는 정답 라벨이 필요한 지도학습. 나머지는 비지도학습 영역.
2	**b. 배정(가까운 중심으로) → 갱신(중심 재계산) → 확인(아직 움직이는가) → 종료**	중심 배정 → 중심 갱신을 반복하다가 변화가 없으면 종료.
3	**d. K가 커질수록 inertia는 감소하므로, inertia가 가장 작다는 이유만으로 K를 고르면 안 된다**	'수학적 최적'이 항상 '현실의 정답'은 아니다. 도메인 지식으로 해석해야 한다.
4	**b. 품종 이름이 아니라 단순한 군집 ID이다**	군집 번호는 임의의 ID. 군집은 분류와 같지 않다.
5	**b. K-means는 거리를 쓰기 때문에 특징의 단위와 크기에 결과가 좌우되기 때문이다**	kg vs mm처럼 숫자가 큰 특징이 거리를 지배하는 것을 막는다.
6	**d. 차원이 늘어나면 공간이 방대해져 데이터가 고립되고, 최근접·최원 거리의 차이가 희미해진다**	필요 격자가 10^1 → 10^100처럼 폭증해 모두가 홀로 고립된다.
7	**a. 데이터의 분산이 가장 크게 퍼지는 방향으로, 가장 큰 고유값에 대응하는 고유벡터이다**	분산 최대 = 정보 손실이 가장 적은 투영 축.
8	**a. 중심화·표준화 → 공분산 계산 → 축 선택(고유값 큰 순) → 투영**	데이터를 원점으로 옮기고 스케일을 맞춘 뒤, 공분산 구조에서 축을 골라 투영.
9	**d. 훈련 데이터로만 기준(fit)을 잡고, 테스트 데이터에는 변환(transform)만 적용한다**	테스트 정보를 미리 보는 'fit' 행위가 누출.
10	**b. 군집은 정답 없이 만든 그룹이므로 실제 품종과 일치한다는 보장이 없고, 비교를 통해 비슷한 부분과 다른 부분을 확인한다**	교차표로 비교해 보면 setosa는 잘 분리되지만 versicolor·virginica는 섞인다.

5주차 · 퍼셉트론에서 다층 퍼셉트론까지

#	정답	풀이
1	**d. 각 입력 정보의 중요도(영향력)를 결정하는 '볼륨 조절기'**	w = 중요도, b = 기본 성향(판단 기준의 위치 이동).
2	**a. z = 0.18 이므로 y = 1**	$z = 0.8\times0.6 + 0.5\times0.4 - 0.5 = 0.48 + 0.2 - 0.5 = 0.18 \geq 0 \rightarrow 1$.
3	**c. 판단 기준(결정 경계)의 위치를 이동시킨다**	우산 예시에서 '챙기기 귀찮아하는 정도'에 해당.
4	**c. 하나의 직선(선형 결정 경계)으로는 XOR을 분리할 수 없기 때문이다**	학습 횟수의 문제가 아니라 모델이 만들 수 있는 경계가 직선 하나이기 때문. XOR 정확도 0.5.
5	**c. 수학적으로 하나의 선형식으로 압축되어 표현력이 늘지 않는다**	$(XW_1)W_2 = X(W_1W_2)$: 행렬곱의 결합법칙.
6	**c. 양수 입력은 0으로 막고, 음수 입력은 그대로 통과시킨다**	ReLU는 음수는 0, 양수는 그대로 통과. 정답 보기는 이를 반대로 서술했다.
7	**a. [0, 0, 4]**	max(0, z)를 원소별로 적용.
8	**d. 너무 극단적이며 미분이 불가능해 신경망을 학습시킬 수 없기 때문이다**	기울기 기반 학습이 불가능.

9	**a. (4×3)**	(N×M)@(M×K) = (N×K), 안쪽 차원 M이 같아야 한다.
10	**a. 아니다. 복잡한 결정 경계가 항상 좋은 것은 아니며 과적합이 생길 수 있다**	XOR에서 은닉 뉴런이 늘면 표현력은 커지지만, 문제 복잡도에 맞는 규모를 골라야 한다.

6주차 · 다층 퍼셉트론은 가중치를 어떻게 스스로 고칠까

#	정답	풀이
1	**a. 가중치**	입력 x → 예측 $\hat{y}$ → 정답 y와 비교 → 가중치 수정.
2	**c. 예측 → 손실 계산 → 기울기 계산 → 가중치 수정**	손실이 있어야 기울기를 구할 수 있다.
3	**c. 2.5**	w_new = 3.0 − 0.1 × 5 = 2.5.
4	**c. 손실이 증가한다**	정답 범주에 준 확률이 낮을수록 큰 벌점.
5	**a. 0.6**	1 − 0.4 = 0.6.
6	**d. 왼쪽(입력)에서 오른쪽(출력)으로 값을 계산하여 예측값을 도출한다**	예측값 $\hat{y}$을 얻는 계산 과정.
7	**a. 오른쪽(출력 측)에서 왼쪽(입력 측)으로 손실의 기울기를 계산한다**	연쇄법칙으로 출력 층부터 거꾸로 기울기를 전달.
8	**b. 0.02**	0.5 × 4 × 0.01 = 0.02.
9	**a. 24**	dL/dx = (dL/du)(du/dx) = 2u × 2 = 4u. x = 3이면 u = 6이므로 24. (원 퀴즈에서 4x로 잘못 계산했다가 4u로 정정한 문제)
10	**a. dL/dw = (dL/dŷ)(dŷ/dh)(dh/dz)(dz/dw)**	연쇄법칙은 각 단계 미분을 '곱한다'.

7주차 · 깊은 신경망, 어떻게 잘 배우게 할까

#	정답	풀이
1	**d. He 초기화, Var(w) = 2/n_in**	He 초기화는 ReLU 계열에 맞춰 분산을 2/n_in으로.
2	**d. 도함수의 최댓값이 0.25에 불과하다**	역전파 때 0.25 이하의 값이 계속 곱해져 앞쪽 층 신호가 사라진다.
3	**b. 2.71**	$v_1 = 1$, $v_2 = 0.9 \cdot 1 + 1 = 1.9$, $v_3 = 0.9 \cdot 1.9 + 1 = 2.71$.
4	**d. L1 규제**	L1은 $\Sigma\|w\|$, L2는 Σw^2.
5	**d. Leaky ReLU로 음수 구간에 작은 기울기를 둔다**	음수 구간에 작은 기울기를 줘서 학습 신호를 살린다.
6	**d. 훈련 중에는 매 단계 무작위로 일부 뉴런의 출력을 0으로 하고, 테스트 때는 모든 뉴런을 켠다**	훈련 때만 랜덤하게 끈다.
7	**d. Adagrad는 보폭이 영구적으로 줄어들 수 있으나, RMSprop은 지수이동평균을 쓴다**	Adagrad는 제곱 기울기를 계속 누적해 보폭이 줄기만 한다.
8	**a. 에폭 6에서 중단, 에폭 4의 가중치 사용**	최저 손실은 에폭 4. 에폭 5, 6에서 개선이 없어 patience 2가 소진되는 에폭 6에서 중단하고 에폭 4로 복원.
9	**a. 2.3**	w_new = 2.0 − 0.1 × (−3.0) = 2.3.
10	**c. 모멘텀의 방향 기억과 RMSprop의 보폭 조정을 결합했다**	Adam = Momentum + RMSprop.

8주차 · 합성곱 신경망

#	정답	풀이
1	**a. 3,136**	28×28×1 → 28×28×32 → 14×14×32 → 14×14×64 → 7×7×64 = 3,136.
2	**b. 최대 풀링(Max Pooling)을 수행할 때 학습해야 할 파라미터가 존재한다**	Max Pooling은 학습 파라미터가 없다.
3	**c. 4,640**	(3×3×16 + 1) × 32 = 145 × 32 = 4,640.
4	**b. 3×3**	(5 − 3 + 0)/1 + 1 = 3.
5	**d. ResNet : 잔차 연결(Skip Connection)**	인셉션 모듈은 GoogLeNet, VGG-16은 3×3 필터 반복.
6	**b. 앞쪽 층에서는 엣지나 색 대비 같은 단순한 패턴을, 깊은 층에서는 물체 수준의 전체 형태를 포착한다**	단순 패턴 → 복합 패턴 → 물체 수준.
7	**b. 입력의 가장자리를 확장하여 출력 크기를 조절한다**	same 패딩이면 입력과 출력 크기가 같다.
8	**a. 작고 균일한 3×3 필터만을 깊게 반복해서 쌓아 올렸다**	단순하고 균일한 구조.
9	**b. 공간 구조가 유지되어 픽셀 간의 이웃 관계가 보존된다**	이웃 관계 보존은 CNN의 장점. MLP는 이미지를 펼치면서 공간 구조를 잃는다.
10	**b. 합성곱 층의 파라미터 수는 입력 이미지의 가로, 세로 크기와 무관하다**	파라미터 수 = 필터 크기 × 입력 채널 수 × 필터 개수 (+ 편향).